

Estimation non paramétrique des processus de Hawkes

Du passage paramétrique -> non paramétrique aux méthodologies : EM, contraste L2 et Wiener-Hopf

Document de synthèse basé sur les explications précédentes et les deux références fournies : Bacry, Mastromatteo et Muzy, "Hawkes processes in finance" ; Ben Allal, "Processus de Hawkes - Modélisation, Simulation et Inférence".

1. Point de départ : modèle de Hawkes

On observe des événements datés sur une fenêtre $[0, T]$. En univarié, on observe $0 < t_1 < \dots < t_n \leq T$. En multivarié, on observe des couples (t_m, k_m) où k_m est le type de l'événement.

Le modèle de Hawkes standard est défini par une intensité conditionnelle. En univarié :

$$\lambda(t) = \mu + \sum_{t_j < t} \phi(t - t_j)$$

En multivarié :

$$\lambda_i(t) = \mu_i + \sum_{j=1}^D \int_0^t \phi_{ij}(t-s) dN_j(s)$$

Le noyau ϕ ou la matrice de noyaux $\Phi = (\phi_{ij})$ mesure l'effet du passé sur l'intensité future. Le modèle standard suppose des noyaux causaux, intégrables et, dans la version excitatrice pure, positifs.

- Causalité : $\phi(t) = 0$ pour $t < 0$.
- Positivité dans le Hawkes linéaire excitateur : $\phi(t) \geq 0$.
- Intégrabilité : $\int_0^\infty \phi(t) dt < \infty$.
- Stabilité univariée : $\int_0^\infty \phi(t) dt < 1$.
- Stabilité multivariée : $\rho(G) < 1$, avec $G_{ij} = \int_0^\infty \phi_{ij}(t) dt$.

2. Passage du paramétrique au non paramétrique

En paramétrique, on choisit une forme explicite du noyau, par exemple :

$$\phi(t) = \alpha e^{-\beta t} \quad \text{ou} \quad \phi(t) = \eta \beta e^{-\beta t}$$

L'estimation consiste alors à estimer quelques paramètres, par exemple μ, α, β ou μ, η, β , généralement par maximum de vraisemblance.

En non paramétrique, on ne choisit plus de forme fermée. On cherche directement à estimer la fonction $\phi(t)$, ou la matrice de fonctions $\Phi(t)$. Comme on ne peut pas estimer une fonction arbitraire sans structure, on introduit une approximation finie : histogrammes, splines, ondelettes, bases locales ou estimateurs par noyaux.

$$\phi(t) \approx \sum_{m=1}^M c_m f_m(t)$$

Le problème devient donc : estimer les coefficients c_m , ou les valeurs de ϕ sur une grille, puis vérifier que le noyau estimé reste compatible avec les hypothèses du modèle.

3. Méthode 1 - EM non paramétrique

3.1 Idée générale

L'EM non paramétrique repose sur la représentation en branchement. Chaque événement observé est soit un immigrant, soit un descendant d'un événement passé. La différence avec l'EM paramétrique est que la M-step ne met pas à jour une formule exponentielle, mais une fonction ϕ estimée directement.

On introduit des variables cachées :

$Z_{i0}=1$ si t_i est immigrant

$Z_{ij}=1$ si t_i est enfant de t_j , avec $j < i$

Pour chaque événement i :

$$Z_{i0} + \sum_{j < i} Z_{ij} = 1$$

3.2 Vraisemblance complétée

La log-vraisemblance complétée univariée est :

$$\ell(\mu, \phi) = \sum_i Z_{i0} \log \mu - \mu T + \sum_i \sum_{j < i} Z_{ij} \log \phi(t_i - t_j) - \int_0^T \phi(u) du$$

Elle sépare la partie immigrant et la partie descendance. Le compensateur reste présent car il représente l'intensité totale accumulée sur $[0, T]$, indépendamment de la généalogie cachée.

3.3 E-step

À l'itération r , on dispose de $\mu^{(r)}$ et $\phi^{(r)}$. On calcule d'abord l'intensité aux événements :

$$\lambda^{(r)}(t_i) = \mu^{(r)} + \sum_{j < i} \phi^{(r)}(t_i - t_j)$$

Puis on calcule les probabilités de parenté :

$$p_{i0}^{(r)} = \frac{\mu^{(r)}}{\lambda^{(r)}(t_i)}$$

$$p_{ij}^{(r)} = \frac{\phi^{(r)}(t_i - t_j)}{\lambda^{(r)}(t_i)}$$

Ces probabilités vérifient :

$$p_{i0}^{(r)} + \sum_{j < i} p_{ij}^{(r)} = 1$$

3.4 M-step par histogramme

Pour coder simplement, on approxime le noyau par une fonction constante par morceaux. On choisit un support $[0, A]$ et une grille :

$$0 = b_0 < b_1 < \dots < b_M = A$$

Avec les bins $B_m = [b_{m-1}, b_m)$, on pose :

$$\phi(u) = \sum_{m=1}^M c_m 1_{u \in B_m}$$

La mise à jour de μ est :

$$\mu^{\text{new}} = \frac{\sum_i p_{i0}}{T}$$

Pour un bin B_m , le numérateur est le nombre attendu de relations parent-enfant dont le délai tombe dans le bin :

$$A_m = \sum_i \sum_{j < i} p_{ij} 1_{t_i - t_j \in B_m}$$

Le dénominateur est l'exposition du bin : le temps pendant lequel chaque parent t_j aurait pu produire un enfant avec un délai dans B_m avant T .

$$E_m = \sum_j [\min(b_m, T - t_j) - b_{m-1}]_+$$

où $x_+ = \max(x, 0)$. La mise à jour est alors :

$$c_m^{\text{new}} = \frac{A_m}{E_m}$$

3.5 Régularisation et stabilité

Sans régularisation, le noyau estimé peut être très irrégulier. On ajoute souvent une pénalité de lissage, par exemple :

$$\gamma \sum_{m=2}^{M-1} (c_{m+1} - 2c_m + c_{m-1})^2$$

On peut aussi utiliser une pénalité L^2 , une pénalité L^1 ou imposer directement $c_m \geq 0$. La stabilité doit aussi être contrôlée :

$$\sum_{m=1}^M c_m |B_m| < 1$$

En multivarié, la même logique s'applique à chaque noyau ϕ_{ij} , mais le nombre de fonctions à estimer est D^2 .

3.6 Algorithme à coder

1. Choisir une grille de retards $B_1, \dots, B_M$ et initialiser $\mu, c_1, \dots, c_M$.
2. Pour chaque événement t_i , calculer $\lambda(t_i)$.
3. Calculer p_{i0} et p_{ij} pour tous les $j < i$.
4. Accumuler les poids p_{ij} par bin de délai $t_i - t_j$.
5. Calculer les expositions E_m .
6. Mettre à jour μ et les c_m .
7. Ajouter lissage ou contraintes si nécessaire.
8. Répéter jusqu'à stabilisation des paramètres ou de la log-vraisemblance.

3.7 Avantages et limites

- Avantage : méthode très interprétable, car elle estime explicitement les probabilités de parenté.
- Avantage : facile à coder avec une base histogramme.
- Limite : coût $O(n^2)$ si toutes les paires $j < i$ sont considérées.
- Limite : mauvaise convergence si le noyau décroît lentement.
- Limite : difficile d'autoriser des noyaux négatifs, car les p_{ij} sont des probabilités.

4. Méthode 2 - Contraste L2

4.1 Idée générale

La méthode par contraste L^2 ne repose pas sur la généalogie cachée. Elle cherche une intensité estimée proche de la vraie intensité. On utilise la propriété :

$$E[dN(t) | F_{t^-}] = \lambda(t) dt$$

On construit alors un contraste empirique qui, en espérance, mesure une erreur quadratique sur l'intensité. En univarié :

$$C(\mu, \phi) = \int_0^T \lambda(t)^2 dt - 2 \int_0^T \lambda(t) dN(t)$$

Comme $\int_0^T \lambda(t) dN(t) = \sum_i \lambda(t_i)$, on écrit :

$$C(\mu, \phi) = \int_0^T \lambda(t)^2 dt - 2 \sum_i \lambda(t_i)$$

4.2 Approximation dans une base

On écrit le noyau dans une base finie :

$$\phi(t) = \sum_{m=1}^M a_m f_m(t)$$

Alors :

$$\lambda(t) = \mu + \sum_{m=1}^M a_m X_m(t)$$

$$X_m(t) = \sum_{t_j < t} f_m(t - t_j)$$

Si on pose $\theta = (\mu, a_1, \dots, a_M)$, l'intensité est linéaire en θ . Le contraste devient quadratique :

$$C(\theta) = \theta^T G \theta - 2b^T \theta$$

avec :

$$G_{kl} = \int_0^T X_k(t) X_l(t) dt$$

$$b_k = \int_0^T X_k(t) dN(t) = \sum_i X_k(t_i)$$

Sans contrainte ni pénalité, le minimiseur satisfait :

$$\hat{\theta} = b$$

4.3 Régularisation

En pratique, G peut être mal conditionnée. On ajoute donc une pénalité. Avec une pénalité ridge :

$$\hat{\theta} = (G + \rho I)^{-1} b$$

Avec une pénalité Lasso :

$$\min_{\theta} \theta^T G \theta - 2b^T \theta + \rho \|\theta\|_1$$

Le Lasso peut être utile en multivarié pour forcer certains noyaux ϕ_{ij} à zéro, donc pour obtenir un réseau d'interactions parcimonieux.

4.4 Contraintes

- Positivité : $\mu \geq 0$ et, si excitation pure, $a_m \geq 0$.
- Stabilité univariée : $\sum_m a_m \int f_m(t) dt < 1$.
- Stabilité multivariée : $\rho(G) < 1$ avec $G_{ij} = \int \phi_{ij}(t) dt$.
- Lissage : pénaliser les variations trop rapides des coefficients.

4.5 Algorithme à coder

9. Choisir une base $f_1, \dots, f_M$: histogrammes, splines ou fonctions locales.
10. Calculer les processus de régression $X_m(t)$.
11. Calculer la matrice $G_{kl} = \int X_k(t) X_l(t) dt$.
12. Calculer le vecteur $b_k = \sum_i X_k(t_i)$.
13. Résoudre un problème quadratique avec contraintes et pénalisation.
14. Reconstruire le noyau estimé $\hat{\phi}(t) = \sum_m \hat{a}_m f_m(t)$.
15. Vérifier la stabilité et la qualité des résidus.

4.6 Avantages et limites

- Avantage : formulation souvent convexe ou quadratique.
- Avantage : compatible avec des pénalisations modernes : ridge, Lasso, lissage.
- Avantage : possible d'autoriser certains effets négatifs dans des extensions non linéaires ou des approximations hors Hawkes positif strict.
- Limite : dépend fortement du choix de la base et de la régularisation.
- Limite : matrices parfois mal conditionnées.

5. Méthode 3 - Inversion de Wiener-Hopf

5.1 Idée générale

La méthode de Wiener-Hopf repose sur les statistiques d'ordre 2. Pour un Hawkes stationnaire, les moyennes et les corrélations déterminent le noyau. On estime une réponse conditionnelle empirique, puis on inverse une équation intégrale.

On définit, pour $t > 0$, la réponse conditionnelle :

$$g_{ij}(t) = \frac{E[dN_i(t) | dN_j(0)=1]}{dt} - \lambda_i$$

où λ_i est l'intensité moyenne de la composante i . Intuitivement, $g_{ij}(t)$ mesure l'excès d'intensité de i à l'horizon t après un événement de type j .

5.2 Équation de Wiener-Hopf

Le noyau direct Φ et la réponse totale g sont reliés par :

$$g(t) = \Phi(t) + \Phi * g(t)$$

C'est-à-dire :

$$g_{ij}(t) = \phi_{ij}(t) + \sum_k \int_0^t \phi_{ik}(s) g_{kj}(t-s) ds$$

Interprétation : g contient l'effet direct Φ , plus tous les effets indirects transmis par des événements intermédiaires. L'objectif est donc de retrouver Φ à partir de g .

5.3 Cas univarié

En univarié :

$$g(t) = \phi(t) + \int_0^t \phi(s) g(t-s) ds$$

En transformée de Laplace, formellement :

$$\hat{g}(z) = \hat{\phi}(z)(1 + \hat{g}(z))$$

Donc :

$$\hat{\phi}(z) = \frac{\hat{g}(z)}{1 + \hat{g}(z)}$$

En pratique, on évite souvent une inversion directe instable de transformée ; on discrétise plutôt l'équation intégrale.

5.4 Algorithme pratique

16. Estimer les intensités moyennes : $\hat{\lambda}_i = N_i(T)/T$.
17. Estimer empiriquement les réponses $\hat{g}_{ij}(t)$, par histogramme ou noyau de lissage.
18. Choisir un support maximal $[0, A]$ pour les noyaux.
19. Choisir une grille de temps $0 = u_1 < \dots < u_M = A$.
20. Discrétiser la convolution : $\int_0^t \phi(s) g(t-s) ds \approx \sum_l w_l \phi(u_l) g(t-u_l)$.
21. Résoudre le système linéaire ou non linéaire discrétisé pour obtenir $\hat{\Phi}(u_l)$.
22. Calculer la matrice des masses $\hat{G}_{ij} = \int \hat{\phi}_{ij}(t) dt$.
23. Estimer l'intensité de base par $\hat{\mu} = (I - \hat{G}) \hat{\lambda}$.

5.5 Estimation empirique de g

Une estimation par histogramme consiste à compter les délais entre les événements de type j et les événements futurs de type i . Pour un bin B_m :

$$\hat{g}_{ij}(B_m) \approx \frac{\#\{(t_l^i, t_k^j) : t_l^i - t_k^j \in B_m\}}{N_j(T) |B_m|} - \hat{\lambda}_i$$

Il faut corriger ou au moins surveiller les effets de bord : près de T , les grands délais ne sont plus observables. Sans correction, le noyau peut être sous-estimé aux grands retards.

5.6 Avantages et limites

- Avantage : très adapté aux grands jeux de données, notamment en finance haute fréquence.
- Avantage : efficace pour des noyaux longs ou à décroissance lente.
- Avantage : ne repose pas sur une généalogie probabiliste, donc peut mieux s'adapter à des effets plus généraux.
- Limite : demande beaucoup de données pour estimer correctement les corrélations.
- Limite : sensible au choix du support, de la grille, du lissage et des corrections de bord.

6. Comparaison synthétique

Méthode	Objet estimé	Idée	Avantages	Limites
EM non paramétrique	μ et ϕ par histogramme ou lissage	Probabilités de parenté immigrant/enfant	Interprétable ; simple à coder	Coût $O(n^2)$; positif seulement ; lent si noyau long
Contraste L2	Coefficients d'une base	Minimisation quadratique de l'erreur d'intensité	Optimisation convexe/quadratique ; régularisable	Choix de base ; conditionnement ; régularisation délicate
Wiener-Hopf	$\Phi(t)$ via les corrélations	Inversion de $g = \Phi + \Phi * g$	Très utile pour gros volumes et noyaux longs	Nécessite beaucoup de données ; estimation de g délicate

7. Choix pratique de la méthode

Le choix dépend de la taille des données, de la nature attendue du noyau et du type d'interprétation recherché.

- Si l'objectif est pédagogique ou si l'on veut coder une première méthode robuste : commencer par EM non paramétrique avec histogrammes.
- Si l'on veut une méthode plus proche de l'optimisation statistique et compatible avec des pénalisations : utiliser le contraste L^2 .
- Si l'on travaille sur beaucoup de données, notamment en finance haute fréquence, et si les noyaux sont longs ou proches d'une loi puissance : privilégier Wiener-Hopf.
- Si les données sont rares, une estimation non paramétrique sera instable ; mieux vaut commencer par un modèle paramétrique simple puis comparer.

8. Validation après estimation

Quelle que soit la méthode, il faut valider le modèle. On calcule l'intensité cumulée estimée :

$$\widehat{\Lambda}(t) = \int_0^t \widehat{\lambda}(s) ds$$

Puis on transforme les dates observées :

$$\tau_i = \widehat{\Lambda}(t_i)$$

Si le modèle est bien spécifié, les inter-arrivées transformées doivent suivre une loi exponentielle de paramètre 1 :

$$\tau_i - \tau_{i-1} \sim \text{Exp}(1)$$

On peut utiliser un QQ-plot, un test de Kolmogorov-Smirnov et l'autocorrélation des résidus. Il faut aussi vérifier la stabilité du noyau estimé.

9. Résumé final

En non paramétrique, on passe de l'estimation de quelques paramètres à l'estimation d'une fonction entière. Cela donne beaucoup plus de flexibilité, mais demande davantage de données et de régularisation.

Les trois méthodes principales sont :

- EM non paramétrique : on estime une généalogie probabiliste, puis on reconstruit le noyau par histogramme ou lissage.
- Contraste L^2 : on projette le noyau sur une base et on résout un problème quadratique pénalisé.
- Wiener-Hopf : on estime les réponses/corrélations empiriques et on inverse l'équation $g = \Phi + \Phi * g$.

La meilleure approche dépend du contexte : EM pour comprendre et coder simplement, contraste L^2 pour une estimation régularisée, Wiener-Hopf pour les données longues et les noyaux à mémoire lente.

Références

Bacry, E., Mastromatteo, I., Muzy, J.-F. (2015). Hawkes processes in finance. arXiv:1502.04592v2.

Ben Allal, L. (2020). Processus de Hawkes - Modélisation, Simulation et Inférence. HAL Id: hal-02947341.