

Processus de Hawkes

Hypotheses, estimation parametrique et estimation non parametrique

Document de synthese base sur Bacry, Mastromatteo et Muzy (2015) et Ben Allal (2020).

Version mise a jour avec les methodes non parametriques : EM non parametrique, contraste L^2 et inversion de Wiener-Hopf.

June 14, 2026

Contents

1	Objet du document	2
2	Modele de Hawkes : notation et hypotheses	2
2.1	Donnees observees	2
2.2	Intensite conditionnelle	2
2.3	Modele univarie	3
2.4	Modele multivarie	3
2.5	Hypotheses structurelles	3
2.5.1	Donnees ponctuelles	4
2.5.2	Dependance au passe	4
2.5.3	Linearite	4
2.5.4	Positivite	4
2.5.5	Causalite	4
2.5.6	Integrabilite	4
2.6	Condition de stabilite	5
3	Estimation parametrique par maximum de vraisemblance	5
3.1	Principe	5
3.2	Vraisemblance observee	6
3.3	Cas exponentiel univarie	6
3.4	Calcul efficace de A_i	7
3.5	Optimisation numerique	7
3.6	Interpretation des parametres	8
3.7	Cas multivarie	8
4	Estimation parametrique par EM	9
4.1	Representation en branchement	9
4.2	Variables cachees	9
4.3	Vraisemblance completee	9
4.4	Pourquoi le compensateur ne change pas	10
4.5	Etape E	10
4.6	Etape M dans le cas exponentiel	11
5	Passage au non parametrique	11
5.1	Ce qui change	11
5.2	Trois grandes familles	12

6 EM non parametrique	12
6.1 Idee	12
6.2 Approximation par histogramme	12
6.3 Etape E	13
6.4 M-step : mise a jour de μ	13
6.5 M-step : mise a jour du noyau par bins	13
6.6 Regularisation	14
6.7 Contraintes	14
6.8 Limites de l'EM non parametrique	15
7 Estimation par contraste L^2	15
7.1 Idee	15
7.2 Approximation dans une base	15
7.3 Forme quadratique	16
7.4 Regularisation	16
7.5 Contraintes	17
7.6 Avantages et limites	17
8 Inversion de Wiener-Hopf	18
8.1 Idee	18
8.2 Equation de Wiener-Hopf	18
8.3 Cas univarie	18
8.4 Etapes pratiques	19
8.4.1 Etape 1 : estimer les intensites moyennes	19
8.4.2 Etape 2 : estimer $g_{ij}(t)$	19
8.4.3 Etape 3 : choisir le support	19
8.4.4 Etape 4 : discretiser l'equation	19
8.4.5 Etape 5 : resoudre le systeme	19
8.4.6 Etape 6 : estimer μ	20
8.5 Avantages et limites	20
9 Comparaison des methodes non parametriques	20
10 Workflow conseille pour coder en Python	21
10.1 Etape 1 : commencer par le parametrique	21
10.2 Etape 2 : coder l'EM non parametrique histogramme	21
10.3 Etape 3 : coder le contraste L^2	21
10.4 Etape 4 : utiliser Wiener-Hopf pour de longues series	22

11 Validation apres estimation	22
12 Synthese finale	23
References indicatives	23

1 Objet du document

Ce document resume les elements essentiels pour comprendre et coder l'estimation d'un modele de Hawkes. Il part des hypotheses du modele, puis presente l'estimation parametrique par maximum de vraisemblance et par EM, avant de passer au cadre non parametrique.

L'objectif est de fournir une lecture operationnelle : quelles sont les hypotheses, quelle vraisemblance on maximise, comment apparait la vraisemblance completee, puis quelles sont les methodes disponibles quand on ne veut pas imposer une forme parametrique au noyau d'excitation.

On distingue deux cadres.

- En estimation parametrique, on choisit une forme explicite du noyau, par exemple $\phi(t) = \alpha e^{-\beta t}$ ou $\phi(t) = \eta \beta e^{-\beta t}$, puis on estime un nombre fini de parametres.
- En estimation non parametrique, on cherche a estimer directement la fonction $\phi(t)$ ou la matrice de fonctions $\Phi(t) = (\phi_{ij}(t))$.

2 Modele de Hawkes : notation et hypotheses

2.1 Donnees observees

En univarie, on observe des dates d'evenements :

$$0 < t_1 < \dots < t_n \leq T.$$

Le processus de comptage associe est :

$$N(t) = \sum_{i=1}^n \mathbf{1}_{t_i \leq t}.$$

En multivarie, on observe des couples :

$$(t_m, k_m)_{m=1, \dots, M},$$

où t_m est la date de l'evenement et $k_m \in \{1, \dots, D\}$ son type. On note alors $N_i(t)$ le nombre d'evenements de type i avant la date t .

2.2 Intensite conditionnelle

L'objet central est l'intensite conditionnelle :

$$\lambda^*(t) = \lim_{h \rightarrow 0} \frac{\mathbb{E}[N(t+h) - N(t) \mid H(t)]}{h},$$

où $H(t)$ represente le passe du processus avant t .

Cette intensite signifie que localement :

$$\mathbb{P}(N(t+h) - N(t) = 1 \mid H(t)) = \lambda^*(t)h + o(h),$$

et :

$$\mathbb{P}(N(t+h) - N(t) > 1 \mid H(t)) = o(h).$$

Ainsi, a tres petite echelle, la probabilite de deux evenements ou plus est negligeable.

2.3 Modele univarie

Le modele de Hawkes lineaire univarie s'ecrit :

$$\lambda(t) = \mu + \sum_{t_j < t} \phi(t - t_j).$$

On peut aussi l'ecrire sous forme integrale :

$$\lambda(t) = \mu + \int_0^t \phi(t - s) \mathrm{d}N(s).$$

Ici :

- $\mu > 0$ est l'intensite de base, ou intensite exogene ;
- ϕ est le noyau d'excitation ;
- $\phi(t - t_j)$ mesure l'effet de l'evenement passe t_j sur l'intensite actuelle.

Le principe est donc :

$$\text{intensite actuelle} = \text{activite de base} + \text{effet cumule du passe}.$$

2.4 Modele multivarie

En dimension D , on ecrit :

$$\lambda_i(t) = \mu_i + \sum_{j=1}^D \int_0^t \phi_{ij}(t - s) \mathrm{d}N_j(s).$$

La fonction ϕ_{ij} mesure l'effet des evenements de type j sur l'intensite des evenements de type i .

2.5 Hypotheses structurelles

Le modele standard repose sur plusieurs hypotheses.

2.5.1 Donnees ponctuelles

Le modele s'applique a des evenements dates. Ce n'est pas une regression classique sur une serie temporelle regulierement echantillonnee.

2.5.2 Dependance au passe

Contrairement a un processus de Poisson homogene, les accroissements ne sont pas independants. Le passe influence le futur via l'intensite conditionnelle.

2.5.3 Linearite

Dans le modele standard :

$$\lambda(t) = \mu + \sum_{t_j < t} \phi(t - t_j).$$

Les contributions des evenements passes s'additionnent. Il n'y a pas de saturation ni de non-linearite dans le modele de base.

2.5.4 Positivite

Le Hawkes lineaire excitateur suppose :

$$\phi(t) \geq 0.$$

En multivarie :

$$\phi_{ij}(t) \geq 0.$$

Cela signifie qu'un evenement passe augmente l'intensite future. Si l'on veut modeliser de l'inhibition, c'est-a-dire des effets negatifs, il faut passer a une extension non lineaire ou a une formulation plus generale.

2.5.5 Causalite

Le noyau est causal :

$$\phi(t) = 0 \quad \text{si } t < 0.$$

Seuls les evenements passes peuvent influencer le present.

2.5.6 Integrabilite

On demande :

$$\int_0^\infty \phi(s) \, ds < \infty.$$

Cette integrale est le nombre moyen de descendants directs produits par un evenement. En multivarie, on considere :

$$G_{ij} = \int_0^\infty \phi_{ij}(s) \, ds.$$

2.6 Condition de stabilite

En univarie, la condition standard de stabilite est :

$$\int_0^\infty \phi(s) \, ds < 1.$$

Cela signifie qu'un evenement genere en moyenne moins d'un enfant direct.

En multivarie, la condition devient :

$$\rho(G) < 1,$$

où $\rho(G)$ est le rayon spectral de la matrice G .

Cette condition garantit le regime sous-critique et evite l'explosion du processus.

3 Estimation parametrique par maximum de vraisemblance

3.1 Principe

En estimation parametrique, on choisit une famille de noyaux :

$$\phi = \phi_\theta.$$

On estime ensuite les parametres θ et l'intensite de base μ en maximisant la vraisemblance des dates observees.

Les exemples classiques sont :

$$\phi(t) = \alpha e^{-\beta t} \mathbf{1}_{t>0},$$

ou :

$$\phi(t) = \eta \beta e^{-\beta t} \mathbf{1}_{t>0}.$$

Les deux conventions sont equivalentes via :

$$\alpha = \eta \beta.$$

Dans la premiere convention :

$$\int_0^\infty \alpha e^{-\beta t} dt = \frac{\alpha}{\beta},$$

donc la stabilite impose :

$$\alpha < \beta.$$

Dans la deuxieme convention :

$$\int_0^\infty \eta \beta e^{-\beta t} dt = \eta,$$

donc la stabilite impose :

$$\eta < 1.$$

3.2 Vraisemblance observee

Pour un processus ponctuel observe sur $[0, T]$, la vraisemblance est :

$$L(\theta) = \prod_{i=1}^n \lambda(t_i; \theta) \exp \left(- \int_0^T \lambda(s; \theta) ds \right).$$

La log-vraisemblance est :

$$\ell(\theta) = \sum_{i=1}^n \log \lambda(t_i; \theta) - \int_0^T \lambda(s; \theta) ds.$$

Le premier terme recompense les parametres qui donnent une forte intensite aux dates ou les evenements sont effectivement observes. Le second terme penalise l'intensite totale accumulee sur toute la fenetre d'observation.

3.3 Cas exponentiel univarie

Avec :

$$\phi(t) = \alpha e^{-\beta t} \mathbf{1}_{t>0},$$

l'intensite est :

$$\lambda(t) = \mu + \sum_{t_j < t} \alpha e^{-\beta(t-t_j)}.$$

Aux dates observees :

$$\lambda(t_i) = \mu + \alpha \sum_{j < i} e^{-\beta(t_i-t_j)}.$$

On pose :

$$A_i = \sum_{j < i} e^{-\beta(t_i - t_j)}.$$

Alors :

$$\lambda(t_i) = \mu + \alpha A_i.$$

Le compensateur vaut :

$$\int_0^T \lambda(s) \, ds = \mu T + \frac{\alpha}{\beta} \sum_{j=1}^n \left(1 - e^{-\beta(T - t_j)}\right).$$

Donc :

$$\ell(\mu, \alpha, \beta) = \sum_{i=1}^n \log(\mu + \alpha A_i) - \mu T - \frac{\alpha}{\beta} \sum_{j=1}^n \left(1 - e^{-\beta(T - t_j)}\right).$$

Si $T = t_n$, on peut ecrire :

$$\ell(\mu, \alpha, \beta) = \sum_{i=1}^n \log(\mu + \alpha A_i) - \mu t_n + \frac{\alpha}{\beta} \sum_{j=1}^n \left(e^{-\beta(t_n - t_j)} - 1\right).$$

3.4 Calcul efficace de A_i

Le calcul direct de :

$$A_i = \sum_{j < i} e^{-\beta(t_i - t_j)}$$

coûte $O(n^2)$. Pour le noyau exponentiel, on utilise la recurrence :

$$A_1 = 0,$$

et, pour $i \geq 2$:

$$A_i = e^{-\beta(t_i - t_{i-1})}(1 + A_{i-1}).$$

Cela réduit le calcul à $O(n)$.

3.5 Optimisation numerique

On cherche :

$$(\hat{\mu}, \hat{\alpha}, \hat{\beta}) = \arg \max_{\mu, \alpha, \beta} \ell(\mu, \alpha, \beta).$$

En Python, on minimise souvent $-\ell$ avec une methode comme `scipy.optimize.minimize`.
Les contraintes sont :

$$\mu > 0, \quad \alpha \geq 0, \quad \beta > 0, \quad \alpha < \beta.$$

Dans la convention $\phi(t) = \eta\beta e^{-\beta t}$, les contraintes deviennent :

$$\mu > 0, \quad 0 \leq \eta < 1, \quad \beta > 0.$$

3.6 Interpretation des parametres

Avec $\phi(t) = \alpha e^{-\beta t}$:

- μ est le taux d'arrivee exogene ;
- α est le saut instantane d'intensite apres un evenement ;
- β est la vitesse de decroissance ;
- α/β est le nombre moyen de descendants directs.

Plus α/β est proche de 1, plus le processus est endogene et proche de l'instabilite.

3.7 Cas multivarie

En multivarie, l'intensite est :

$$\lambda_i(t) = \mu_i + \sum_{j=1}^D \sum_{t_m^j < t} \phi_{ij}(t - t_m^j).$$

La log-vraisemblance est :

$$\ell(\mu, \Phi) = \sum_{m=1}^M \log \lambda_{k_m}(t_m) - \sum_{i=1}^D \int_0^T \lambda_i(t) dt.$$

Avec des noyaux exponentiels :

$$\phi_{ij}(t) = \eta_{ij} \beta_{ij} e^{-\beta_{ij} t} \mathbf{1}_{t>0}.$$

La stabilite se controle par :

$$\rho \left(\left[\int_0^\infty \phi_{ij}(t) dt \right]_{i,j} \right) < 1.$$

Dans la convention $\phi_{ij}(t) = \eta_{ij} \beta_{ij} e^{-\beta_{ij} t}$, cela revient a :

$$\rho((\eta_{ij})_{i,j}) < 1.$$

4 Estimation parametrique par EM

4.1 Representation en branchement

L'algorithme EM repose sur l'interpretation suivante : un processus de Hawkes lineaire positif peut etre vu comme une population d'evenements.

- Des immigrants arrivent avec intensite de base μ .
- Chaque evenement peut generer des descendants selon le noyau ϕ .
- Ces descendants peuvent eux-memes generer d'autres descendants.

Les parents des evenements ne sont pas observes. Ce sont les variables cachees de l'EM.

4.2 Variables cachees

Pour chaque evenement t_i , on introduit :

$$Z_{i0} = 1$$

si l'evenement i est immigrant, et :

$$Z_{ij} = 1$$

si l'evenement i est enfant de t_j , avec $j < i$.

On impose :

$$Z_{i0} + \sum_{j < i} Z_{ij} = 1.$$

Chaque evenement a donc exactement une origine.

4.3 Vraisemblance completee

La vraisemblance observee contient :

$$\lambda(t_i) = \mu + \sum_{j < i} \phi(t_i - t_j).$$

Ce terme melange toutes les causes possibles. Si la genealogie etait observee, la contribution de t_i serait :

$$\mu^{Z_{i0}} \prod_{j < i} \phi(t_i - t_j)^{Z_{ij}}.$$

Ainsi, la vraisemblance completee est :

$$L_c(\mu, \phi) = \left[\prod_{i=1}^n \mu^{Z_{i0}} \prod_{j<i} \phi(t_i - t_j)^{Z_{ij}} \right] \exp \left(-\mu T - \sum_{j=1}^n \int_0^{T-t_j} \phi(u) \, du \right).$$

La log-vraisemblance completee est :

$$\ell_c(\mu, \phi) = \sum_{i=1}^n Z_{i0} \log \mu - \mu T + \sum_{i=1}^n \sum_{j<i} Z_{ij} \log \phi(t_i - t_j) - \sum_{j=1}^n \int_0^{T-t_j} \phi(u) \, du.$$

4.4 Pourquoi le compensateur ne change pas

La completion ajoute l'information de genealogie, mais ne change pas les dates observees ni l'intensite totale disponible sur $[0, T]$.

Le compensateur reste :

$$\exp \left(- \int_0^T \lambda(s) \, ds \right).$$

Or :

$$\int_0^T \lambda(s) \, ds = \mu T + \sum_{j=1}^n \int_{t_j}^T \phi(s - t_j) \, ds = \mu T + \sum_{j=1}^n \int_0^{T-t_j} \phi(u) \, du.$$

La genealogie Z indique qui a produit les evenements observees, mais elle ne modifie pas le volume d'intensite accumule ni l'absence d'evenements supplementaires.

4.5 Etape E

A l'iteration r , on dispose de $\mu^{(r)}$ et $\phi^{(r)}$. On calcule :

$$\lambda^{(r)}(t_i) = \mu^{(r)} + \sum_{j<i} \phi^{(r)}(t_i - t_j).$$

Puis :

$$p_{i0}^{(r)} = \frac{\mu^{(r)}}{\lambda^{(r)}(t_i)},$$

et :

$$p_{ij}^{(r)} = \frac{\phi^{(r)}(t_i - t_j)}{\lambda^{(r)}(t_i)}.$$

On a :

$$p_{i0}^{(r)} + \sum_{j<i} p_{ij}^{(r)} = 1.$$

4.6 Etape M dans le cas exponentiel

Avec :

$$\phi(u) = \eta \beta e^{-\beta u},$$

la fonction Q de l'EM est :

$$Q(\mu, \eta, \beta) = \hat{N}_0 \log \mu - \mu T + \hat{N}_1 \log \eta + \hat{N}_1 \log \beta - \beta \hat{S} - \eta \sum_{j=1}^n \left(1 - e^{-\beta(T-t_j)}\right),$$

où :

$$\hat{N}_0 = \sum_i p_{i0}, \quad \hat{N}_1 = \sum_i \sum_{j < i} p_{ij},$$

et :

$$\hat{S} = \sum_i \sum_{j < i} p_{ij} (t_i - t_j).$$

La mise a jour de μ est :

$$\mu^{new} = \frac{\hat{N}_0}{T}.$$

Si β est fixe :

$$\eta^{new} = \frac{\hat{N}_1}{\sum_{j=1}^n (1 - e^{-\beta(T-t_j)})}.$$

Si β est inconnu, on maximise numériquement Q en β , puis on recalcule η .

5 Passage au non parametrique

5.1 Ce qui change

En parametrique, on choisit une forme :

$$\phi(t) = \alpha e^{-\beta t}.$$

On estime alors quelques parametres.

En non parametrique, on n'impose pas cette forme. On estime directement :

$$\phi(t),$$

ou en multivarie :

$$\Phi(t) = (\phi_{ij}(t))_{i,j=1,\dots,D}.$$

Comme une fonction contient une infinite de valeurs, on travaille toujours avec une approximation finie : histogrammes, splines, fonctions constantes par morceaux, bases locales ou noyaux de lissage.

5.2 Trois grandes familles

Les methodologies usuelles sont :

1. EM non parametrique ;
2. estimation par contraste L^2 ;
3. inversion de Wiener-Hopf a partir des statistiques d'ordre 2.

Elles repondent a des objectifs differents. L'EM est interpretable mais peut etre lent. Le contraste L^2 transforme l'estimation en un probleme quadratique. Wiener-Hopf est particulierement adapte aux donnees longues, notamment en finance haute frequence.

6 EM non parametrique

6.1 Idee

L'EM non parametrique conserve les memes variables cachees que l'EM parametrique :

$$Z_{i0}, \quad Z_{ij}.$$

La difference est que la M-step ne met plus a jour un couple de parametres comme (α, β) , mais une fonction ϕ .

La log-vraisemblance completee reste :

$$\ell_c(\mu, \phi) = \sum_i Z_{i0} \log \mu - \mu T + \sum_i \sum_{j < i} Z_{ij} \log \phi(t_i - t_j) - \sum_j \int_0^{T-t_j} \phi(u) \, du.$$

6.2 Approximation par histogramme

On choisit un support maximal $[0, A]$ et une grille :

$$0 = b_0 < b_1 < \dots < b_M = A.$$

On note :

$$B_m = [b_{m-1}, b_m).$$

On approxime :

$$\phi(u) = \sum_{m=1}^M c_m \mathbf{1}_{u \in B_m}.$$

Les inconnues sont donc :

$$\mu, c_1, \dots, c_M.$$

6.3 Etape E

A l'iteration r :

$$\lambda^{(r)}(t_i) = \mu^{(r)} + \sum_{j < i} \phi^{(r)}(t_i - t_j).$$

Puis :

$$p_{i0}^{(r)} = \frac{\mu^{(r)}}{\lambda^{(r)}(t_i)},$$

et :

$$p_{ij}^{(r)} = \frac{\phi^{(r)}(t_i - t_j)}{\lambda^{(r)}(t_i)}.$$

6.4 M-step : mise a jour de μ

Le nombre attendu d'immigrants est :

$$\hat{N}_0 = \sum_i p_{i0}.$$

Donc :

$$\mu^{new} = \frac{\hat{N}_0}{T}.$$

6.5 M-step : mise a jour du noyau par bins

Pour le bin B_m , le numerateur est le nombre attendu de relations parent-enfant dont le delai tombe dans ce bin :

$$C_m = \sum_i \sum_{j < i} p_{ij} \mathbf{1}_{t_i - t_j \in B_m}.$$

Le denominateur est l'exposition totale du bin. Pour un parent t_j , la longueur de temps pendant laquelle il aurait pu produire un enfant avec un delai dans $B_m = [b_{m-1}, b_m)$ est :

$$[\min(b_m, T - t_j) - b_{m-1}]_+,$$

où $[x]_+ = \max(x, 0)$.

Ainsi :

$$E_m = \sum_{j=1}^n [\min(b_m, T - t_j) - b_{m-1}]_+.$$

La mise a jour est :

$$c_m^{new} = \frac{C_m}{E_m}.$$

6.6 Regularisation

Sans regularisation, l'estimation peut etre bruittee. On ajoute souvent une penalite de lissage, par exemple :

$$\gamma \sum_{m=2}^{M-1} (c_{m+1} - 2c_m + c_{m-1})^2.$$

On peut aussi utiliser une penalite L^2 :

$$\gamma \sum_m c_m^2,$$

ou une penalite L^1 :

$$\gamma \sum_m |c_m|.$$

6.7 Contraintes

Pour un Hawkes excitateur pur :

$$c_m \geq 0.$$

La stabilite impose :

$$\sum_{m=1}^M c_m |B_m| < 1.$$

En multivarie, il faut remplacer cette contrainte par une condition de rayon spectral sur la matrice des masses estimees.

6.8 Limites de l'EM non parametrique

L'EM non parametrique est intuitif, mais il a deux limites majeures.

- Il peut etre couteux, car l'E-step considere toutes les paires (j, i) avec $j < i$, donc typiquement $O(n^2)$.
- Il repose sur une interpretation probabiliste des contributions $\phi(t_i - t_j)$, ce qui est naturel pour des noyaux positifs, mais pas pour des noyaux negatifs ou inhibiteurs.

Il est donc adapte aux noyaux positifs et plutot localises.

7 Estimation par contraste L^2

7.1 Idee

La methode par contraste L^2 evite d'utiliser directement la log-vraisemblance. Elle cherche une intensite estimee proche de la vraie intensite au sens quadratique.

En univarie :

$$\lambda(t) = \mu + \int_0^t \phi(t-s) \mathrm{d}N(s).$$

Le contraste est :

$$C(\mu, \phi) = \int_0^T \lambda(t)^2 \mathrm{d}t - 2 \int_0^T \lambda(t) \mathrm{d}N(t).$$

Comme :

$$\int_0^T \lambda(t) \mathrm{d}N(t) = \sum_{i=1}^n \lambda(t_i),$$

on obtient :

$$C(\mu, \phi) = \int_0^T \lambda(t)^2 \mathrm{d}t - 2 \sum_{i=1}^n \lambda(t_i).$$

On estime :

$$(\hat{\mu}, \hat{\phi}) = \arg \min_{\mu, \phi} C(\mu, \phi).$$

7.2 Approximation dans une base

On choisit une base $f_1, \dots, f_M$ et on ecrit :

$$\phi(t) = \sum_{m=1}^M a_m f_m(t).$$

Alors :

$$\lambda(t) = \mu + \sum_{m=1}^M a_m X_m(t),$$

où :

$$X_m(t) = \int_0^t f_m(t-s) \mathrm{d}N(s) = \sum_{t_j < t} f_m(t-t_j).$$

En posant :

$$\theta = (\mu, a_1, \dots, a_M),$$

l'intensite est lineaire en θ :

$$\lambda(t) = \theta^\top X(t).$$

7.3 Forme quadratique

Le contraste devient :

$$C(\theta) = \theta^\top G \theta - 2b^\top \theta,$$

avec :

$$G_{kl} = \int_0^T X_k(t) X_l(t) \mathrm{d}t,$$

et :

$$b_k = \int_0^T X_k(t) \mathrm{d}N(t) = \sum_{i=1}^n X_k(t_i).$$

Le minimiseur non contraint verifie :

$$G\hat{\theta} = b.$$

Donc, si G est inversible :

$$\hat{\theta} = G^{-1}b.$$

7.4 Regularisation

En pratique, G peut etre mal conditionnee. On ajoute une regularisation.

Avec une penalite ridge :

$$C_\rho(\theta) = \theta^\top G \theta - 2b^\top \theta + \rho \|\theta\|_2^2.$$

Le minimiseur est :

$$\hat{\theta} = (G + \rho I)^{-1} b.$$

Avec une penalite L^1 :

$$C_\rho(\theta) = \theta^\top G \theta - 2b^\top \theta + \rho \|\theta\|_1,$$

on obtient un probleme de type Lasso, utile pour forcer la parcimonie.

7.5 Contraintes

On peut imposer :

$$\mu \geq 0,$$

et, si la base est positive :

$$a_m \geq 0.$$

Avec un histogramme, la stabilite impose :

$$\sum_{m=1}^M a_m |B_m| < 1.$$

En multivarie :

$$\rho \left(\left[\int_0^\infty \phi_{ij}(t) dt \right]_{i,j} \right) < 1.$$

7.6 Avantages et limites

Le contraste L^2 est interessant parce qu'il conduit a un probleme quadratique. Il est souvent plus simple a optimiser que la log-vraisemblance.

Ses limites sont :

- choix sensible de la base ;
- choix de la regularisation ;
- conditionnement parfois mauvais de la matrice G ;
- besoin de beaucoup de donnees pour estimer finement le noyau.

8 Inversion de Wiener-Hopf

8.1 Idee

La methode de Wiener-Hopf utilise les statistiques d'ordre 2. Pour un Hawkes stationnaire, les moyennes et les correlations determinent le noyau.

On definit, pour $t > 0$:

$$g_{ij}(t) = \frac{\mathbb{E}[\mathrm{d}N_i(t) \mid \mathrm{d}N_j(0) = 1]}{\mathrm{d}t} - \Lambda_i,$$

où :

$$\Lambda_i = \frac{\mathbb{E}[\mathrm{d}N_i(t)]}{\mathrm{d}t}.$$

La quantite $g_{ij}(t)$ mesure l'excès d'intensite de la composante i a l'horizon t apres un evenement de type j a la date 0.

8.2 Equation de Wiener-Hopf

Le noyau verifie :

$$g(t) = \Phi(t) + \Phi * g(t),$$

c'est-a-dire :

$$g(t) = \Phi(t) + \int_0^t \Phi(s)g(t-s) \mathrm{d}s.$$

Cette equation dit que g est la reponse totale : effet direct plus effets indirects. Le noyau Φ est la reponse directe que l'on veut retrouver.

8.3 Cas univarie

En univarie :

$$g(t) = \phi(t) + \int_0^t \phi(s)g(t-s) \mathrm{d}s.$$

En transformee de Laplace :

$$\hat{g}(z) = \hat{\phi}(z) + \hat{\phi}(z)\hat{g}(z).$$

Donc :

$$\hat{\phi}(z) = \frac{\hat{g}(z)}{1 + \hat{g}(z)}.$$

En pratique, on evite une inversion analytique delicate et on discretise plutot l'equation integrale.

8.4 Etapes pratiques

8.4.1 Etape 1 : estimer les intensites moyennes

Pour chaque composante :

$$\hat{\Lambda}_i = \frac{N_i(T)}{T}.$$

8.4.2 Etape 2 : estimer $g_{ij}(t)$

Pour chaque paire (i, j) , on regarde les delais entre un evenement de type j et un evenement futur de type i .

Avec des bins B_m , on peut approximer :

$$\hat{g}_{ij}(u_m) \approx \frac{\#\{(t_\ell^i, t_k^j) : t_\ell^i - t_k^j \in B_m\}}{N_j(T)|B_m|} - \hat{\Lambda}_i.$$

Il faut corriger ou au moins surveiller les effets de bord : pres de la fin T , tous les delais ne sont plus observables.

8.4.3 Etape 3 : choisir le support

On choisit un support maximal $[0, A]$ tel que :

$$\Phi(t) \approx 0 \quad \text{pour } t > A.$$

8.4.4 Etape 4 : discretiser l'equation

Sur une grille $u_1, \dots, u_M$, on approxime :

$$\int_0^t \Phi(s)g(t-s) \, ds \approx \sum_{\ell: u_\ell < t} w_\ell \Phi(u_\ell)g(t-u_\ell).$$

On obtient alors un systeme discret :

$$g(t_m) = \Phi(t_m) + \sum_{\ell} w_\ell \Phi(u_\ell)g(t_m - u_\ell).$$

L'inconnue est :

$$\Phi(u_1), \dots, \Phi(u_M).$$

8.4.5 Etape 5 : resoudre le systeme

On resout le systeme lineaire ou quasi-lineaire discret pour obtenir $\hat{\Phi}$.

8.4.6 Etape 6 : estimer μ

Une fois $\hat{\Phi}$ estime, on calcule la matrice des masses :

$$\hat{G}_{ij} = \int_0^\infty \hat{\phi}_{ij}(t) dt.$$

On utilise la relation stationnaire :

$$\Lambda = (I - G)^{-1} \mu.$$

Donc :

$$\hat{\mu} = (I - \hat{G}) \hat{\Lambda}.$$

En univariate :

$$\hat{\mu} = \hat{\Lambda} \left(1 - \int_0^\infty \hat{\phi}(t) dt \right).$$

8.5 Avantages et limites

Wiener-Hopf est souvent tres utile quand on dispose de beaucoup de donnees, notamment en finance haute frequence. Il est adapte aux noyaux longs et peut traiter plus naturellement certains effets que l'EM probabiliste ne gere pas bien.

Ses limites sont :

- il faut bien estimer les correlations empiriques ;
- il faut choisir un support A ;
- il faut gerer les effets de bord ;
- la discretisation peut etre instable si les donnees sont insuffisantes ou si le bruit est trop fort.

9 Comparaison des methodes non parametriques

Method	Idee centrale	Avantages	Limites
EM non parametrique	Estimer les probabilites de parente puis mettre a jour le noyau par bins ou par lissage.	Tres interpretable ; proche de la representation en branchement.	Cout $O(n^2)$; noyaux positifs ; lent si noyau long.
Contraste L^2	Minimiser une erreur quadratique sur l'intensite dans une base finie.	Probleme quadratique ; possibilite de regularisation ridge ou Lasso.	Choix de base ; conditionnement ; regularisation delicate.

Wiener-Hopf	Inverser les statistiques d'ordre 2 pour retrouver le noyau direct.	Adapte aux gros jeux de donnees ; bon pour noyaux longs.	Estimation de correlations delicate ; effets de bord ; discretisation.
-------------	---	--	--

10 Workflow conseille pour coder en Python

10.1 Etape 1 : commencer par le parametrique

Avant de coder le non parametrique, il est preferable de coder un Hawkes univarié exponentiel et de verifier :

1. simulation ;
2. log-vraisemblance ;
3. estimation MLE ;
4. validation par residus.

Cela permet de controler les conventions, notamment la difference entre $\alpha e^{-\beta t}$ et $\eta \beta e^{-\beta t}$.

10.2 Etape 2 : coder l'EM non parametrique histogramme

C'est la methode non parametrique la plus intuitive.

1. Choisir une grille $B_1, \dots, B_M$.
2. Initialiser μ et les c_m .
3. Calculer les intensites $\lambda(t_i)$.
4. Calculer p_{i0} et p_{ij} .
5. Accumuler les poids p_{ij} par bin.
6. Diviser par les expositions E_m .
7. Mettre a jour μ .
8. Repeter jusqu'a convergence.

10.3 Etape 3 : coder le contraste L^2

On choisit une base, par exemple des histogrammes, puis on construit :

$$G_{kl} = \int_0^T X_k(t) X_l(t) dt,$$

et :

$$b_k = \sum_i X_k(t_i).$$

Ensuite on resout :

$$\hat{\theta} = \arg \min_{\theta} \theta^{\top} G \theta - 2b^{\top} \theta + \text{penalite.}$$

10.4 Etape 4 : utiliser Wiener-Hopf pour de longues series

Cette methode est particulierement pertinente si l'on soupconne un noyau a longue memoire ou proche d'une loi puissance.

Les grandes etapes sont :

1. estimer Λ ;
2. estimer les fonctions $g_{ij}(t)$;
3. discretiser l'equation $g = \Phi + \Phi * g$;
4. resoudre pour Φ ;
5. calculer $G = \int \Phi$;
6. en deduire $\mu = (I - G)\Lambda$;
7. verifier la stabilite $\rho(G) < 1$.

11 Validation apres estimation

Quelle que soit la methode d'estimation, il faut valider le modele.

On calcule l'intensite cumulee estimee :

$$\hat{\Lambda}(t) = \int_0^t \hat{\lambda}(s) \, ds.$$

Puis on transforme les dates :

$$\tau_i = \hat{\Lambda}(t_i).$$

Si le modele est bien specifie, les increments :

$$\tau_i - \tau_{i-1}$$

doivent suivre approximativement une loi exponentielle de parametre 1.

On peut donc utiliser :

- un QQ-plot contre une loi exponentielle $\text{Exp}(1)$;
- un test de Kolmogorov-Smirnov ;
- une analyse des residus de martingale ;
- une comparaison hors echantillon de log-vraisemblance.

12 Synthèse finale

Le modèle de Hawkes standard repose sur :

$$\lambda(t) = \mu + \sum_{t_j < t} \phi(t - t_j),$$

avec :

$$\mu > 0, \quad \phi(t) \geq 0, \quad \phi(t) = 0 \text{ pour } t < 0,$$

et :

$$\int_0^\infty \phi(t) dt < 1.$$

En paramétrique, on impose une forme de ϕ et on estime un nombre fini de paramètres par maximum de vraisemblance ou par EM.

En non paramétrique, on estime directement le noyau. Les trois méthodes principales sont :

- EM non paramétrique, basé sur les probabilités de parenté ;
- contraste L^2 , basé sur une approximation dans une base et une minimisation quadratique ;
- inversion de Wiener-Hopf, basée sur les statistiques d'ordre 2 et les corrélations.

Le choix dépend de la taille des données, de la forme attendue du noyau, de la positivité ou non des interactions, et de l'objectif : interprétation, prédiction, ou reconstruction fine des dépendances.

References indicatives

Bacry, E., Mastromatteo, I. et Muzy, J.-F. (2015). *Hawkes processes in finance*. Survey sur les processus de Hawkes multivariés et leurs applications en finance haute fréquence.

Ben Allal, L. (2020). *Processus de Hawkes : Modélisation, Simulation et Inférence*. Mémoire sur la modélisation, la simulation et l'inférence des processus de Hawkes, incluant les noyaux exponentiels, puissance et marques.

Daley, D. J. et Vere-Jones, D. *An Introduction to the Theory of Point Processes*. Référence classique sur les processus ponctuels, les intensités conditionnelles et les vraisemblances.

Ogata, Y. Travaux sur la simulation par thinning, l'estimation et les modèles de type ETAS.