

Processus de comptage en temps continu

ACI, intensité stochastique SCI, processus de Hawkes et traitement opérationnel de la saisonnalité

Cette note synthétise le cadre de Bauwens et Hautsch, précise la dynamique ACI, montre dans quelles conditions elle peut être remplacée par une dynamique de Hawkes, et propose plusieurs méthodes concrètes pour estimer ou fixer la saisonnalité d'un processus de comptage.

Version du 16 juillet 2026

Table des matières

Résumé exécutif	3
1 Cadre : processus de comptage, intensité et temps transformé	5
1.1 Processus univarié et multivarié	5
1.2 Compensateur et intensité intégrée	5
1.3 Vraisemblance générique	6
2 Décomposition SCI de Bauwens et Hautsch	6
2.1 Composante observable et facteur latent commun	6
2.2 Dynamique du facteur latent	6
2.3 Identification	7
2.4 Ce que le facteur latent représente	7
3 La dynamique ACI	8
3.1 Structure générale	8
3.2 Innovation fondée sur l'intensité intégrée	8
3.3 Interprétation économique ou opérationnelle	9
3.4 Version multivariée	9
3.5 Différence entre dynamique observable et facteur latent	10
4 Comment Bauwens et Hautsch traitent la saisonnalité	10
4.1 Saisonnalité déterministe dans la composante observable	10
4.2 Saisonnalité du chargement latent	10
4.3 Normalisation et positivité	11
5 Peut-on remplacer l'ACI par un Hawkes ?	11
5.1 Hawkes linéaire multivarié	11
5.2 ACI et Hawkes : mécanismes différents	12
5.3 Remplacement littéral dans le SCI	12
5.4 Spécification additive recommandée	13
5.5 Stabilité du Hawkes	13
6 Estimation du SCI avec facteur latent	13
6.1 Vraisemblance conditionnelle aux états latents	13
6.2 Intégration des états	14
6.3 Alternatives modernes	14
7 Méthodes opérationnelles pour la saisonnalité	15
7.1 Méthode 1 : taux empiriques par tranches	15
7.2 Méthode 2 : baseline constante par morceaux et pénalisée	15
7.3 Méthode 3 : spline sur le logarithme de la baseline	16
7.4 Méthode 4 : forme de Fourier	16
7.5 Méthode 5 : estimation séparée par Poisson ou GAM	16
7.6 Méthode 6 : temps d'activité ou business time	16
7.7 Méthode 7 : profils hiérarchiques	17
8 Confusion entre saisonnalité, Hawkes et facteur latent	17
8.1 Pourquoi l'identification est délicate	17
8.2 Séparation par échelle temporelle	18

8.3	Réplication entre cycles	18
8.4	Baseline flexible et branching ratio	18
9	Procédure d'estimation recommandée	18
9.1	Étape 0 : préparation des données	18
9.2	Étape 1 : estimation de la saisonnalité seule	19
9.3	Étape 2 : modèle sans dynamique événementielle	19
9.4	Étape 3 : ajout d'un Hawkes	19
9.5	Étape 4 : stabilité de la saisonnalité	19
9.6	Étape 5 : ajout éventuel d'un facteur latent	19
9.7	Étape 6 : diagnostics	20
10	Choix de modèle selon l'objectif	20
11	Spécifications concrètes proposées	21
11.1	Modèle minimal robuste	21
11.2	Version avec facteur latent exogène	21
11.3	Version SCI multiplicative fidèle au papier	22
12	Plan d'implémentation algorithmique	22
12.1	Pré-estimation de la saisonnalité	22
12.2	Recursion Hawkes exponentielle	22
12.3	Paramétrisation numérique	23
12.4	Validation hors échantillon	23
13	Points de vigilance statistiques	23
13.1	Nombre de cycles et complexité de la saisonnalité	23
13.2	Hétérogénéité entre jours	23
13.3	Ruptures structurelles	23
13.4	Bords de fenêtre	24
13.5	Covariables et prévisibilité	24
14	Conclusion	24
A	Annexe A : formules récapitulatives	25
A.1	SCI original	25
A.2	ACI univarié simple	25
A.3	Hawkes saisonnier	25
A.4	Hawkes avec facteur latent sur la baseline	25
A.5	Saisonnalité positive et normalisée	25
B	Annexe B : liste de contrôle empirique	25
	Références	26

Résumé exécutif

Le point de départ est un processus de comptage $N(t)$, ou un vecteur de processus $N(t) = (N_1(t), \dots, N_K(t))'$, observé à des dates irrégulières. L'objet fondamental n'est pas un nombre de comptes par intervalle arbitraire, mais l'*intensité conditionnelle* $\lambda_k(t | \mathcal{F}_t^-)$, c'est-à-dire le taux instantané d'arrivée d'un événement de type k conditionnellement à toute l'histoire passée.

Dans le modèle SCI de Bauwens et Hautsch, l'intensité est décomposée en une composante observable et une composante latente commune :

$$\lambda_k(t) = \lambda_{o,k}(t) (\lambda_i^*)^{\sigma_k^*}, \quad t_{i-1} < t \leq t_i, \quad (1)$$

avec

$$\log \lambda_i^* = a^* \log \lambda_{i-1}^* + u_i^*, \quad u_i^* \sim \mathcal{N}(0, 1). \quad (2)$$

La composante $\lambda_{o,k}(t)$ contient notamment une dynamique ACI, une intensité de base entre événements et une fonction déterministe de saisonnalité. La saisonnalité n'est donc pas, dans la spécification de base, le facteur stochastique lui-même. Une extension permet néanmoins de faire varier selon l'heure le chargement σ_k^* du facteur latent, ce qui revient à rendre saisonnière la variance de la contribution latente.

La dynamique ACI est une dynamique autorégressive du niveau d'intensité mise à jour à chaque événement par une innovation construite à partir de l'intensité intégrée. Dans sa forme univariée simple :

$$\lambda_o(t) = \Phi_i \lambda_0(t) s(\tau(t)), \quad t_{i-1} < t \leq t_i, \quad (3)$$

$$\tilde{\Phi}_i = \omega + \alpha \varepsilon_{i-1} + \beta (\tilde{\Phi}_{i-1} - \omega), \quad (4)$$

$$\varepsilon_i = 1 - \int_{t_{i-1}}^{t_i} \lambda_o(u) du, \quad \Phi_i = \exp(\tilde{\Phi}_i). \quad (5)$$

Un événement plus précoce qu'attendu donne une intensité intégrée faible, donc une innovation positive et, si $\alpha > 0$, une augmentation de l'intensité future.

Cette dynamique peut être remplacée par un Hawkes. Deux formes sont particulièrement utiles :

$$\text{forme SCI multiplicative : } \lambda_k(t) = \left[\mu_k(t) + \sum_{\ell=1}^K \int_{(-\infty, t)} \phi_{k\ell}(t-u) dN_\ell(u) \right] \exp(\sigma_k z(t)), \quad (6)$$

$$\text{forme séparant exogène et endogène : } \lambda_k(t) = \mu_k(t) \exp(\sigma_k z(t)) + \sum_{\ell=1}^K \int_{(-\infty, t)} \phi_{k\ell}(t-u) dN_\ell(u). \quad (7)$$

La deuxième écriture est souvent plus interprétable : la baseline et le facteur latent représentent l'activité exogène, tandis que les noyaux de Hawkes représentent la propagation endogène déclenchée par les événements.

Pour la saisonnalité, la solution la plus opérationnelle n'est pas nécessairement de tout estimer conjointement dans un SCI complexe. Une procédure robuste consiste à :

1. calculer des taux par tranches horaires en corrigeant de l'exposition effective ;
2. lisser ces taux par une pénalité de différences, un spline ou une forme de Fourier ;
3. normaliser le profil à moyenne unitaire ;

4. garder ce profil fixé lors de l'estimation du Hawkes ;
5. vérifier que les résultats sont stables lorsque la granularité et le lissage changent.

Recommandation centrale. Pour une première spécification empirique, estimer un modèle

$$\lambda_k(t) = \bar{\mu}_k s_k(\tau(t)) + \sum_{\ell=1}^K \sum_{t_j^\ell < t} \alpha_{k\ell} \beta_{k\ell} e^{-\beta_{k\ell}(t-t_j^\ell)},$$

avec s_k estimée séparément et normalisée. Ajouter ensuite un facteur latent uniquement si les résidus montrent encore une dépendance lente, une surdispersion ou une covariation commune non expliquée.

1 Cadre : processus de comptage, intensité et temps transformé

1.1 Processus univarié et multivarié

Soit $N(t)$ le nombre d'événements observés dans l'intervalle $(0, t]$. Les dates d'événements sont notées

$$0 < t_1 < t_2 < \dots < t_n \leq T.$$

Dans un modèle multivarié, $N_k(t)$ compte les événements de type k et

$$N(t) = \sum_{k=1}^K N_k(t)$$

est le processus agrégé. On note $m_i \in \{1, \dots, K\}$ le type du i -ème événement agrégé et

$$y_i^k = \mathbf{1}\{m_i = k\}.$$

L'intensité conditionnelle du processus k est définie par

$$\lambda_k(t \mid \mathcal{F}_{t-}) = \lim_{h \downarrow 0} \frac{\Pr(N_k(t+h) - N_k(t) = 1 \mid \mathcal{F}_{t-})}{h}. \quad (8)$$

Elle résume toute la loi conditionnelle locale du processus. Pour un petit intervalle h ,

$$\Pr(N_k(t+h) - N_k(t) = 1 \mid \mathcal{F}_{t-}) \simeq \lambda_k(t \mid \mathcal{F}_{t-})h.$$

1.2 Compensateur et intensité intégrée

Le compensateur est

$$\Lambda_k(t) = \int_0^t \lambda_k(u) du. \quad (9)$$

Sous une spécification correcte, les incréments d'intensité intégrée entre événements transformés suivent une loi exponentielle standard. Dans le cas univarié,

$$E_i = \Lambda(t_i) - \Lambda(t_{i-1}) = \int_{t_{i-1}}^{t_i} \lambda(u) du \sim \text{Exp}(1). \quad (10)$$

Cette propriété, conséquence du théorème de changement de temps aléatoire, est à la fois :

- le fondement de l'innovation ACI;
- le fondement de la vraisemblance de processus ponctuel;
- l'outil principal de diagnostic après estimation.

La variable

$$U_i = 1 - e^{-E_i}$$

doit être approximativement uniforme sur $[0, 1]$. On peut donc contrôler le modèle par des QQ-plots exponentiels, des tests d'uniformité sur U_i , des tests d'autocorrélation et des tests d'indépendance.

1.3 Vraisemblance générique

Pour un processus multivarié observé sur $[0, T]$, la log-vraisemblance est, à une constante près,

$$\ell(\theta) = \sum_{i=1}^n \log \lambda_{m_i}(t_i; \theta) - \sum_{k=1}^K \int_0^T \lambda_k(t; \theta) dt. \quad (11)$$

Le premier terme récompense une intensité élevée aux dates effectivement observées. Le second pénalise une intensité trop élevée sur l'ensemble de la fenêtre d'observation.

Une analyse fondée sur des comptes agrégés par minute ou par heure peut être utile, mais elle perd une partie de l'information temporelle et peut confondre saisonnalité, dépendance à court terme et surdispersion. Lorsque les dates exactes sont disponibles, la vraisemblance de processus ponctuel est généralement le point de départ naturel.

2 Décomposition SCI de Bauwens et Hautsch

2.1 Composante observable et facteur latent commun

Le modèle SCI, pour *Stochastic Conditional Intensity*, généralise le modèle ACI en ajoutant un facteur commun non observé [1]. La spécification centrale est

$$\lambda_k(t) = \lambda_{o,k}(t) \left(\lambda_{\tilde{N}(t)+1}^* \right)^{\sigma_k^*} \quad (12)$$

où $\tilde{N}(t)$ est le processus de comptage gauche-continu du processus agrégé. Le facteur λ_i^* est mis à jour aux dates du processus agrégé, puis reste constant entre deux événements.

En posant

$$l_i^* = \log \lambda_i^*,$$

on obtient

$$\log \lambda_k(t) = \log \lambda_{o,k}(t) + \sigma_k^* l_i^*, \quad t_{i-1} < t \leq t_i. \quad (13)$$

Cette écriture montre que le facteur latent agit comme un choc commun sur le logarithme des intensités, avec un chargement spécifique σ_k^* .

2.2 Dynamique du facteur latent

Bauwens et Hautsch spécifient le logarithme du facteur comme un AR(1) gaussien en temps événementiel :

$$l_i^* = a^* l_{i-1}^* + u_i^*, \quad u_i^* \stackrel{i.i.d.}{\sim} \mathcal{N}(0, 1). \quad (14)$$

La variance de l'innovation est fixée à 1 pour identifier l'échelle du facteur. L'amplitude de la contribution latente au processus k est portée par σ_k^* :

$$\text{Var}(\sigma_k^* u_i^*) = (\sigma_k^*)^2. \quad (15)$$

Le facteur est commun aux composantes. Pour deux processus k et ℓ , il crée mécaniquement une covariation conditionnelle de leurs logarithmes d'intensité :

$$\text{Cov}(\sigma_k^* l_i^*, \sigma_\ell^* l_i^*) = \sigma_k^* \sigma_\ell^* \text{Var}(l_i^*). \quad (16)$$

Le signe relatif des chargements indique si le facteur affecte les deux processus dans le même sens ou en sens opposé.

2.3 Identification

Puisque la loi de l_i^* est symétrique, les transformations

$$(l_i^*, \sigma_1^*, \dots, \sigma_K^*) \quad \text{et} \quad (-l_i^*, -\sigma_1^*, \dots, -\sigma_K^*)$$

donnent la même intensité. On impose donc une convention de signe, par exemple

$$\sigma_1^* > 0.$$

Il faut également éviter qu'un intercept libre dans le facteur latent ne soit confondu avec le niveau moyen de la baseline. La spécification à moyenne nulle du logarithme du facteur et la normalisation de la saisonnalité sont essentielles.

2.4 Ce que le facteur latent représente

Le facteur latent est destiné à absorber des variations persistantes et communes qui ne sont pas complètement mesurées par les événements passés ou les covariables disponibles. Dans une application financière, il peut représenter un flux général d'information non observé. Dans d'autres domaines, il pourrait correspondre à :

- un état commun de demande ou de charge ;
- une exposition environnementale non mesurée ;
- un régime d'activité commun à plusieurs catégories d'événements ;
- une hétérogénéité dynamique non observée.

Il ne faut pas lui attribuer automatiquement une interprétation causale. C'est d'abord une composante statistique destinée à reproduire de la dépendance commune et de la surdispersion.




FIGURE 1 – Décomposition conceptuelle : saisonnalité répétitive, facteur latent lent et excitation déclenchée par les événements. Les courbes sont illustratives et ne représentent pas des données de l'article original.

3 La dynamique ACI

3.1 Structure générale

ACI signifie *Autoregressive Conditional Intensity*. Dans une spécification proportionnelle, la composante observable peut s'écrire

$$\lambda_{o,k}(t) = \Phi_i^k \lambda_{0,k}(t) s_k(t), \quad t_{i-1} < t \leq t_i. \quad (17)$$

Les trois composantes ont des fonctions différentes :

- $\lambda_{0,k}(t)$ décrit la forme du risque entre deux événements, souvent en fonction du temps écoulé depuis le dernier événement ;
- $s_k(t)$ représente la saisonnalité déterministe ;
- Φ_i^k est le niveau dynamique mis à jour après l'événement $i - 1$.

La positivité est assurée par une paramétrisation log-linéaire :

$$\Phi_i^k = \exp \left(\tilde{\Phi}_i^k + z'_{i-1} \gamma_k \right), \quad (18)$$

où z_{i-1} contient des covariables observées.

3.2 Innovation fondée sur l'intensité intégrée

Dans la version univariée élémentaire, on définit

$$\varepsilon_i = 1 - \Lambda(t_{i-1}, t_i) = 1 - \int_{t_{i-1}}^{t_i} \lambda_o(u) du. \quad (19)$$

Comme $\Lambda(t_{i-1}, t_i) \sim \text{Exp}(1)$ sous le modèle,

$$\mathbb{E}(\varepsilon_i) = 0.$$

La dynamique ACI(1,1) s'écrit alors

$$\boxed{\tilde{\Phi}_i = \omega + \alpha \varepsilon_{i-1} + \beta (\tilde{\Phi}_{i-1} - \omega).} \quad (20)$$

Une écriture équivalente est

$$\tilde{\Phi}_i = (1 - \beta)\omega + \alpha \varepsilon_{i-1} + \beta \tilde{\Phi}_{i-1}.$$

3.3 Interprétation économique ou opérationnelle

Supposons $\alpha > 0$.

- Si l'événement arrive plus tôt que prévu, l'intensité intégrée $\Lambda(t_{i-1}, t_i)$ est inférieure à 1. Donc $\varepsilon_i > 0$ et l'intensité future augmente.
- Si l'événement arrive plus tard que prévu, $\Lambda(t_{i-1}, t_i) > 1$. Donc $\varepsilon_i < 0$ et l'intensité future diminue.
- Le coefficient β contrôle la persistance du niveau dynamique.

L'ACI n'est pas un processus latent : à paramètres donnés, $\tilde{\Phi}_i$ est calculé récursivement à partir des événements observés. Il s'agit donc d'une dynamique *observation-driven*, comparable à un GARCH pour une variance conditionnelle.

3.4 Version multivariée

Dans un système de K processus, l'innovation peut être construite à partir du type de l'événement le plus récent :

$$\varepsilon_i = \sum_{k=1}^K \left[1 - \int_{t_{N_k(t_i)-1}^k}^{t_{N_k(t_i)}^k} \lambda_k(u) du \right] y_i^k. \quad (21)$$

Une autre option est l'innovation du processus agrégé :

$$\tilde{\varepsilon}_i = 1 - \sum_{k=1}^K \int_{t_{i-1}}^{t_i} \lambda_k(u) du. \quad (22)$$

La mise à jour multivariée de Russell peut être représentée par

$$\boxed{\tilde{\Phi}_i = \sum_{k=1}^K \left(A^k \varepsilon_{i-1} + B^k \tilde{\Phi}_{i-1} \right) y_{i-1}^k.} \quad (23)$$

Le type du dernier événement sélectionne les coefficients d'innovation et de persistance. Un événement de type k peut donc modifier simultanément l'ensemble des intensités.

3.5 Différence entre dynamique observable et facteur latent

Le SCI combine deux mécanismes :

$$\text{dynamique observable : } \tilde{\Phi}_i = f(\tilde{\Phi}_{i-1}, \varepsilon_{i-1}, m_{i-1}), \quad (24)$$

$$\text{dynamique latente : } l_i^* = a^* l_{i-1}^* + u_i^*. \quad (25)$$

La première réagit mécaniquement aux erreurs de prévision observables. La seconde produit une variation aléatoire persistante qui ne peut pas être reconstruite exactement à partir de l'histoire des événements.

4 Comment Bauwens et Hautsch traitent la saisonnalité

4.1 Saisonnalité déterministe dans la composante observable

Dans le cadre ACI/SCI, la saisonnalité est généralement un multiplicateur déterministe $s_k(t)$:

$$\lambda_{o,k}(t) = \Phi_i^k \lambda_{0,k}(t) s_k(t). \quad (26)$$

Une paramétrisation linéaire par splines utilisée dans cette littérature est

$$s_k(t) = 1 + \sum_{j=1}^S v_{kj} (t - \tau_j) \mathbf{1}\{t > \tau_j\}, \quad (27)$$

avec des nœuds τ_j fixés à l'avance. Cette fonction est affine entre deux nœuds et sa pente change en chaque τ_j .

Une forme de Fourier flexible constitue une alternative :

$$\log s_k(\tau) = \sum_{r=1}^R \left[a_{kr} \cos\left(\frac{2\pi r \tau}{P}\right) + b_{kr} \sin\left(\frac{2\pi r \tau}{P}\right) \right]. \quad (28)$$

Elle est adaptée à une saisonnalité réellement périodique, car elle raccorde naturellement le début et la fin du cycle.

4.2 Saisonnalité du chargement latent

Le papier envisage aussi de faire varier l'amplitude du facteur latent selon l'heure. Une spécification possible est

$$\sigma_{k,i}^* = \sigma_k^* \left[1 + \sum_{m=1}^M v_m^* \mathbf{1}\{\tau(t_i) \geq \bar{\tau}_m\} (\tau(t_i) - \bar{\tau}_m) \right]. \quad (29)$$

Le modèle devient

$$\log \lambda_k(t) = \log \lambda_{o,k}(t) + \sigma_{k,i}^* l_i^*. \quad (30)$$

Cette extension ne rend pas aléatoire la courbe moyenne de saisonnalité. Elle rend saisonnière la *variance* de la contribution latente :

$$\text{Var}(\sigma_{k,i}^* l_i^* \mid \tau(t_i)) = (\sigma_{k,i}^*)^2 \text{Var}(l_i^*). \quad (31)$$

Distinction importante. Une moyenne saisonnière élevée signifie que davantage d'événements sont attendus à cette heure de façon répétitive. Une variance latente saisonnière élevée signifie que l'incertitude ou l'hétérogénéité non observée est plus forte à cette heure. Les deux phénomènes ne sont pas interchangeables.

4.3 Normalisation et positivité

La forme linéaire $1 + \sum_j v_j(t - \tau_j)_+$ n'assure pas automatiquement la positivité pour toutes les valeurs des paramètres. Une paramétrisation plus robuste est

$$s_k(\tau) = \exp [B(\tau)' \gamma_k - c_k(\gamma_k)], \quad (32)$$

où $B(\tau)$ est une base de splines ou de Fourier et c_k impose la normalisation

$$\frac{1}{P} \int_0^P s_k(\tau) d\tau = 1. \quad (33)$$

Cette normalisation sépare le niveau moyen $\bar{\mu}_k$ du profil relatif s_k :

$$\mu_k(t) = \bar{\mu}_k s_k(\tau(t)). \quad (34)$$

Sans normalisation, multiplier s_k par une constante et diviser $\bar{\mu}_k$ par la même constante ne change pas l'intensité. Le modèle est alors mal identifié ou numériquement instable.

5 Peut-on remplacer l'ACI par un Hawkes ?

5.1 Hawkes linéaire multivarié

Un processus de Hawkes multivarié standard est défini par

$$\lambda_k(t) = \mu_k(t) + \sum_{\ell=1}^K \int_{(-\infty, t)} \phi_{k\ell}(t - u) dN_\ell(u). \quad (35)$$

Sous forme événementielle,

$$\lambda_k(t) = \mu_k(t) + \sum_{\ell=1}^K \sum_{t_j^\ell < t} \phi_{k\ell}(t - t_j^\ell). \quad (36)$$

Avec un noyau exponentiel normalisé,

$$\phi_{k\ell}(v) = \alpha_{k\ell} \beta_{k\ell} e^{-\beta_{k\ell} v} \mathbf{1}\{v > 0\}, \quad (37)$$

on a

$$\int_0^\infty \phi_{k\ell}(v) dv = \alpha_{k\ell}. \quad (38)$$

Le paramètre $\alpha_{k\ell}$ mesure alors le nombre moyen d'événements directs de type k engendrés par un événement de type ℓ , dans l'interprétation en branchements.

5.2 ACI et Hawkes : mécanismes différents

TABLE 1 – Comparaison conceptuelle entre ACI et Hawkes

Dimension	ACI	Hawkes
Déclencheur	Erreur de prévision de la durée ou de l'intensité intégrée	Occurrence de chaque événement passé
Horloge	Mise à jour principalement en temps événementiel	Décroissance en temps continu
Forme dynamique	Niveau autorégressif, souvent constant entre événements	Somme d'impulsions et de noyaux décroissants
Signe de l'effet	Peut augmenter ou réduire le niveau selon l'innovation	Hawkes linéaire positif : excitation ; extensions non linéaires pour inhibition
Interprétation	Adaptation du niveau conditionnel aux surprises	Propagation ou contagion événementielle
Analogie	GARCH ou modèle observation-driven	Processus de clusters / branchements




FIGURE 2 – Illustration : une ACI modifie un niveau par paliers aux dates d'événements, tandis qu'un Hawkes ajoute des impulsions qui décroissent en temps continu.

5.3 Remplacement littéral dans le SCI

On peut remplacer la composante ACI observable par un Hawkes :

$$\lambda_k(t) = \left[\mu_k(t) + \sum_{\ell=1}^K \int_{(-\infty, t)} \phi_{k\ell}(t-u) dN_\ell(u) \right] \exp(\sigma_k z(t)). \quad (39)$$

Cette écriture reste fidèle à l'idée multiplicative du SCI. Cependant, le facteur latent multiplie à la fois la baseline et l'excitation. Le nombre effectif de descendants associés à un noyau dépend alors de l'état latent, ce qui complique l'interprétation du branching ratio.

5.4 Spécification additive recommandée

Pour séparer plus clairement l'exogène de l'endogène, on peut écrire

$$\lambda_k(t) = \underbrace{\bar{\mu}_k s_k(\tau(t)) \exp(\sigma_k z(t))}_{\text{activité de fond exogène}} + \underbrace{\sum_{\ell=1}^K \int_{(-\infty, t)} \phi_{k\ell}(t-u) dN_\ell(u)}_{\text{propagation endogène}}. \quad (40)$$

Cette spécification n'est plus exactement le SCI multiplicatif original, mais elle est souvent préférable lorsque l'objectif substantif consiste à distinguer :

variation externe commune et auto- ou cross-excitation.

5.5 Stabilité du Hawkes

Dans le cas stationnaire à noyaux intégrables, on définit la matrice de reproduction

$$G_{k\ell} = \int_0^\infty \phi_{k\ell}(u) du. \quad (41)$$

Une condition standard de stabilité du Hawkes linéaire est

$$\rho(G) < 1, \quad (42)$$

où $\rho(G)$ est le rayon spectral. Si $\rho(G)$ est proche de 1, le processus est très persistant et l'estimation devient sensible à la baseline et aux bords de la fenêtre d'observation.

Une baseline saisonnière trop rigide peut attribuer à l'auto-excitation des variations qui sont en réalité déterministes. Le branching ratio est alors souvent surestimé. Une baseline excessivement flexible peut au contraire absorber les clusters de court terme et sous-estimer l'excitation.

6 Estimation du SCI avec facteur latent

6.1 Vraisemblance conditionnelle aux états latents

Soit $l_{1:n}^* = (l_1^*, \dots, l_n^*)$. Conditionnellement à cette trajectoire, l'intensité intégrée sur $(t_{i-1}, t_i]$ est

$$\Lambda_k(t_{i-1}, t_i | l_i^*) = \exp(\sigma_k^* l_i^*) \Lambda_{o,k}(t_{i-1}, t_i), \quad (43)$$

avec

$$\Lambda_{o,k}(t_{i-1}, t_i) = \int_{t_{i-1}}^{t_i} \lambda_{o,k}(u) du.$$

La contribution de processus ponctuel à la log-vraisemblance complète est

$$\ell_{PP}(\theta, l_{1:n}^*) = \sum_{i=1}^n \sum_{k=1}^K y_i^k [\log \lambda_{o,k}(t_i) + \sigma_k^* l_i^*] \quad (44)$$

$$- \sum_{i=1}^n \sum_{k=1}^K \exp(\sigma_k^* l_i^*) \Lambda_{o,k}(t_{i-1}, t_i). \quad (45)$$

Il faut ajouter la densité de transition de l'AR(1) :

$$\ell_{\text{etat}}(\theta, l_{1:n}^*) = \sum_{i=1}^n \log p_{\theta}(l_i^* | l_{i-1}^*). \quad (46)$$

Ainsi,

$$\ell_c(\theta, l_{1:n}^*) = \ell_{PP}(\theta, l_{1:n}^*) + \ell_{\text{etat}}(\theta, l_{1:n}^*). \quad (47)$$

6.2 Intégration des états

La vraisemblance marginale est

$$L(\theta) = \int_{\mathbb{R}^n} \exp\{\ell_c(\theta, l_{1:n}^*)\} dl_1^* \cdots dl_n^*. \quad (48)$$

L'intégrale est de dimension égale au nombre d'événements. Elle n'a généralement pas de forme fermée.

Bauwens et Hautsch utilisent le maximum de vraisemblance simulé associé à l'*Efficient Importance Sampling* (EIS). On construit une densité auxiliaire séquentielle

$$q(l_{1:n}; \psi) = \prod_{i=1}^n q_i(l_i | l_{i-1}; \psi_i) \quad (49)$$

proche de la loi a posteriori des états. Avec R trajectoires simulées $l_{1:n}^{(r)} \sim q$, l'estimateur est

$$\widehat{L}_R(\theta) = \frac{1}{R} \sum_{r=1}^R \frac{\exp\{\ell_c(\theta, l_{1:n}^{(r)})\}}{q(l_{1:n}^{(r)}; \psi)}. \quad (50)$$

Les paramètres de la loi auxiliaire sont ajustés pour réduire la variance des poids d'importance.

6.3 Alternatives modernes

Selon la dimension et la structure choisie, les alternatives sont :

- filtre particulaire avec maximisation de vraisemblance ;
- particle MCMC ;
- MCMC avec échantillonnage des états latents ;
- approximation de Laplace ou méthodes INLA pour certaines discrétisations ;
- inférence variationnelle ;
- représentation en espace d'états discret après binning fin, au prix d'une approximation temporelle.

Le choix doit être guidé par la précision requise et le volume d'événements. Un facteur latent par événement peut devenir très coûteux lorsque n est très grand. Une alternative opérationnelle consiste à faire évoluer le facteur sur une grille temporelle plus grossière que les événements.

7 Méthodes opérationnelles pour la saisonnalité

7.1 Méthode 1 : taux empiriques par tranches

Divisons chaque cycle, par exemple une journée, en B tranches $I_1, \dots, I_B$. Pour le jour d , notons :

- C_{kdb} le nombre d'événements de type k dans la tranche b ;
- E_{db} la durée d'exposition effectivement observée dans cette tranche.

Le taux brut est

$$\hat{r}_{kb} = \frac{\sum_{d=1}^D C_{kdb}}{\sum_{d=1}^D E_{db}}. \quad (51)$$

La correction par l'exposition est indispensable en présence de jours incomplets, de fermetures, de pannes ou de fenêtres d'observation variables.

On normalise ensuite :

$$\hat{s}_{kb} = \frac{\hat{r}_{kb}}{\frac{1}{P} \sum_{c=1}^B |I_c| \hat{r}_{kc}}, \quad (52)$$

de sorte que

$$\frac{1}{P} \sum_{b=1}^B |I_b| \hat{s}_{kb} = 1. \quad (53)$$

Version robuste. Calculer un taux pour chaque jour et chaque tranche, puis agréger les taux quotidiens par médiane ou moyenne tronquée. Cette procédure réduit l'influence de journées exceptionnelles, de nouvelles majeures ou de dysfonctionnements de collecte.

7.2 Méthode 2 : baseline constante par morceaux et pénalisée

On peut estimer conjointement une baseline positive par tranches :

$$\mu_k(t) = \exp(\gamma_{kb}), \quad \tau(t) \in I_b. \quad (54)$$

La partie intégrée est simple :

$$\int_0^T \mu_k(t) dt = \sum_{b=1}^B E_b \exp(\gamma_{kb}). \quad (55)$$

Pour éviter une courbe trop accidentée, on maximise

$$\ell_{\text{pen}}(\theta, \gamma) = \ell(\theta, \gamma) - \kappa \sum_{b=1}^{B-1} (\gamma_{k,b+1} - \gamma_{kb})^2. \quad (56)$$

Une pénalité de second ordre,

$$\kappa \sum_{b=2}^{B-1} (\gamma_{k,b+1} - 2\gamma_{kb} + \gamma_{k,b-1})^2, \quad (57)$$

produit généralement un profil plus lisse. Pour un cycle sans discontinuité réelle, la pénalité peut être rendue cyclique entre les premières et dernières tranches.

7.3 Méthode 3 : spline sur le logarithme de la baseline

Une spécification souple et positive est

$$\log \mu_k(t) = \beta_{0k} + B(\tau(t))' \gamma_k. \quad (58)$$

Il est préférable d'utiliser un spline cyclique lorsque la fin du cycle doit rejoindre son début. Une pénalisation de la courbure,

$$\kappa \int_0^P [s_k''(\tau)]^2 d\tau, \quad (59)$$

permet de contrôler le compromis biais-variance.

7.4 Méthode 4 : forme de Fourier

La forme de Fourier est

$$\log s_k(\tau) = \sum_{r=1}^R \left[a_{kr} \cos\left(\frac{2\pi r \tau}{P}\right) + b_{kr} \sin\left(\frac{2\pi r \tau}{P}\right) \right]. \quad (60)$$

Ses avantages sont : périodicité exacte, faible nombre de paramètres pour des profils lisses, intégration numérique stable. Son inconvénient est la tendance à produire des oscillations si R est trop élevé ou si le profil comporte des ruptures nettes.

7.5 Méthode 5 : estimation séparée par Poisson ou GAM

On peut discrétiser le temps uniquement pour estimer la saisonnalité. Pour des comptes C_{kdb} et des expositions E_{db} ,

$$C_{kdb} \sim \text{Poisson}(E_{db} \exp\{\eta_{kdb}\}), \quad (61)$$

avec

$$\eta_{kdb} = \alpha_k + f_k(\tau_b) + \delta_d + \mathbf{x}'_{db} \beta_k. \quad (62)$$

Ici f_k est un spline cyclique et δ_d peut représenter un effet de jour. Le profil estimé

$$\hat{s}_k(\tau) = \frac{\exp\{\hat{f}_k(\tau)\}}{P^{-1} \int_0^P \exp\{\hat{f}_k(v)\} dv} \quad (63)$$

peut ensuite être injecté comme offset fixé dans le modèle de Hawkes en temps continu.

Cette stratégie est souvent le meilleur compromis opérationnel : le lissage est traité par des outils standards de régression de Poisson ou de GAM, tandis que le Hawkes est estimé sur les dates exactes.

7.6 Méthode 6 : temps d'activité ou business time

Si tous les processus partagent approximativement la même saisonnalité $s(t)$, on définit

$$u(t) = \int_0^t s(v) dv. \quad (64)$$

Les dates transformées sont $u_i = u(t_i)$. Un modèle stationnaire peut alors être estimé dans l'horloge u .

Si $\tilde{\lambda}(u)$ est l'intensité dans le temps transformé, l'intensité en temps calendaire est

$$\lambda(t) = s(t) \tilde{\lambda}(u(t)). \quad (65)$$

Dans un Hawkes, la mémoire devient

$$\phi(u(t) - u(t_j)) \quad (66)$$

et non $\phi(t - t_j)$. La durée de mémoire est donc mesurée en unités d'activité. Cette méthode est élégante mais impose une interprétation spécifique de l'horloge.




FIGURE 3 – Exemple illustratif d'estimation d'un profil saisonnier par taux de tranches, lissage pénalisé et normalisation à moyenne unitaire.

7.7 Méthode 7 : profils hiérarchiques

Lorsque les K composantes ont des profils proches mais pas identiques, on peut écrire

$$\log s_k(\tau) = f_0(\tau) + f_k^{\text{dev}}(\tau), \quad (67)$$

avec une pénalité forte sur f_k^{dev} . Cette structure emprunte de l'information entre processus tout en autorisant des différences spécifiques. Elle est plus stable que l'estimation de K courbes totalement indépendantes lorsque certains types d'événements sont rares.

8 Confusion entre saisonnalité, Hawkes et facteur latent

8.1 Pourquoi l'identification est délicate

Les trois composantes peuvent produire des amas d'événements :

- une saisonnalité élevée crée des clusters qui se répètent aux mêmes heures ;
- un Hawkes crée des clusters déclenchés par les événements récents ;
- un facteur latent persistant crée des régimes d'activité élevée ou faible qui ne se répètent pas nécessairement à heure fixe.

Sur un échantillon court, ces mécanismes peuvent être presque observationnellement équivalents.

8.2 Séparation par échelle temporelle

Une règle de travail est

$$\text{échelle de variation de } s(t) \gg \text{échelle de décroissance de } \phi(t). \quad (68)$$

Si les noyaux Hawkes décroissent en quelques secondes, la baseline ne devrait pas varier librement à la seconde. Si le noyau a une mémoire de plusieurs heures, une simple saisonnalité horaire peut ne pas suffire à séparer les effets.

8.3 Réplication entre cycles

La saisonnalité est identifiable grâce à la répétition de nombreux cycles comparables. La courbe $s(\tau)$ doit être estimée à partir de la variation moyenne entre jours, et non à partir d'un seul jour. Les anomalies propres à une journée doivent être captées par des effets de jour, des covariables ou un facteur latent, pas par la fonction saisonnière commune.

8.4 Baseline flexible et branching ratio

Omi, Hirata et Aihara montrent qu'une mauvaise spécification du taux de fond temporel peut modifier sensiblement l'estimation de l'endogénéité dans un Hawkes [10]. Le problème peut être résumé ainsi :

$$\begin{aligned} \text{baseline trop rigide} &\implies \text{excitation estimée trop forte,} \\ \text{baseline trop flexible à court terme} &\implies \text{excitation estimée trop faible.} \end{aligned}$$

Le choix du lissage ne doit pas être effectué uniquement par la qualité d'ajustement in-sample. Il faut examiner la stabilité des paramètres Hawkes, les performances hors échantillon et les résidus transformés pour plusieurs niveaux de lissage raisonnables.

9 Procédure d'estimation recommandée

9.1 Étape 0 : préparation des données

Avant toute estimation :

1. vérifier l'ordre strict des dates et traiter les événements simultanés ;
2. définir clairement les périodes d'exposition et retirer les périodes où aucun événement ne pouvait être observé ;
3. décider si les ruptures entre cycles sont réelles ou si le temps doit être concaténé ;
4. documenter les changements de définition, de collecte ou de régime ;
5. créer les indicatrices de type et les covariables prévisibles.

Les événements simultanés sont problématiques pour un processus ponctuel simple. On peut : utiliser une résolution plus fine si elle existe, agréger les événements simultanés en marques, introduire un ordre déterministe justifié, ou utiliser un modèle de comptes en temps discret si la simultanéité est substantielle.

9.2 Étape 1 : estimation de la saisonnalité seule

Estimer un modèle de Poisson/GAM ou des taux par tranches avec exposition. Vérifier :

- la stabilité du profil entre sous-périodes ;
- la sensibilité à la largeur des tranches ;
- la présence de jours atypiques ;
- l'opportunité d'un profil commun ou spécifique à chaque type.

Normaliser le profil à moyenne unitaire.

9.3 Étape 2 : modèle sans dynamique événementielle

Estimer

$$\lambda_k(t) = \bar{\mu}_k s_k(\tau(t)). \quad (69)$$

Ce modèle constitue une référence. Les résidus permettent d'évaluer la dépendance restante. Une autocorrélation positive des résidus ou un excès de petits temps transformés signale généralement des clusters non captés.

9.4 Étape 3 : ajout d'un Hawkes

Estimer

$$\lambda_k(t) = \bar{\mu}_k s_k(\tau(t)) + \sum_{\ell=1}^K \sum_{t_j^\ell < t} \phi_{k\ell}(t - t_j^\ell). \quad (70)$$

Commencer par une somme limitée de noyaux exponentiels. Pour plusieurs échelles de mémoire,

$$\phi_{k\ell}(u) = \sum_{q=1}^Q \alpha_{k\ell q} \beta_q e^{-\beta_q u} \mathbf{1}\{u > 0\}. \quad (71)$$

Fixer éventuellement une grille de β_q et estimer seulement les amplitudes permet de réduire les difficultés numériques.

9.5 Étape 4 : stabilité de la saisonnalité

Réestimer le Hawkes sous plusieurs traitements raisonnables :

- tranches de 5, 10, 15 ou 30 minutes selon l'application ;
- spline avec différents degrés de pénalisation ;
- profil commun et profils spécifiques ;
- estimation de la saisonnalité sur une période d'apprentissage séparée.

Les conclusions substantielles ne doivent pas dépendre d'une seule spécification arbitraire de saisonnalité.

9.6 Étape 5 : ajout éventuel d'un facteur latent

Un facteur latent est justifié si, après saisonnalité et Hawkes :

- une autocorrélation lente demeure dans les résidus ;
- les comptes sur des fenêtres longues restent surdispersés ;
- les processus présentent une covariation commune non reproduite par les excitations croisées ;
- l'ajout du facteur améliore la vraisemblance hors échantillon et la calibration.

On peut commencer avec un facteur latent sur une grille temporelle, par exemple toutes les 5 ou 15 minutes, avant d'utiliser un état à chaque événement. Cela réduit fortement la dimension latente.

9.7 Étape 6 : diagnostics

Pour chaque type k , calculer les temps transformés entre ses événements :

$$E_i^k = \int_{t_{i-1}^k}^{t_i^k} \hat{\lambda}_k(u) du. \quad (72)$$

Examiner :

- moyenne et variance de E_i^k ;
- QQ-plot par rapport à $\text{Exp}(1)$;
- autocorrélations de $E_i^k - 1$ et de fonctions non linéaires ;
- uniformité de $1 - e^{-E_i^k}$;
- résidus par heure, jour et régime ;
- calibration des comptes prédits sur plusieurs horizons.

Pour un Hawkes, vérifier aussi :

- le rayon spectral de la matrice de reproduction ;
- la robustesse aux conditions initiales et aux effets de bord ;
- la stabilité des noyaux lorsque la fenêtre d'estimation change ;
- l'existence de paramètres proches des frontières de stabilité.

10 Choix de modèle selon l'objectif

TABLE 2 – Guide de choix pratique

Objectif principal	Modèle conseillé au départ	Commentaire
Prévoir le nombre d'événements à court terme	Saison + Hawkes	Bon compromis entre performance et interprétabilité ; utiliser une baseline estimée sur données d'apprentissage.
Mesurer une contagion ou une propagation entre types	Hawkes multivarié avec saisonnalité soigneusement contrôlée	L'interprétation des noyaux dépend fortement de la baseline ; tester la stabilité des branching ratios.

Objectif principal	Modèle conseillé au départ	Commentaire
Reproduire une persistance conditionnelle fondée sur les surprises de durée	ACI	L'innovation par intensité intégrée est naturelle; dynamique observation-driven facile à filtrer.
Capturer un état commun non observé	SCI ou Hawkes avec facteur latent	Estimation plus coûteuse; vérifier que la dynamique croisée ne suffit pas.
Données très abondantes et besoin opérationnel	Saisonnalité fixée + Hawkes exponentiel parcimonieux	Recursions rapides; régularisation utile en grande dimension.
Peu de cycles saisonniers	Baseline paramétrique simple + forte régularisation	Une saisonnalité très flexible n'est pas identifiable; privilégier des informations externes.
Profil saisonniers similaires entre catégories	Modèle hiérarchique ou profil commun	Réduit la variance et le nombre de paramètres.

11 Spécifications concrètes proposées

11.1 Modèle minimal robuste

La spécification de départ recommandée est

$$\lambda_k(t) = \bar{\mu}_k s_k(\tau(t)) + \sum_{\ell=1}^K \sum_{t_j^\ell < t} \alpha_{k\ell} \beta_{k\ell} e^{-\beta_{k\ell}(t-t_j^\ell)}. \quad (73)$$

Contraintes :

$$\bar{\mu}_k > 0, \quad \alpha_{k\ell} \geq 0, \quad \beta_{k\ell} > 0, \quad \rho(A) < 1, \quad (74)$$

où $A = (\alpha_{k\ell})$. Le profil est normalisé :

$$\frac{1}{P} \int_0^P s_k(\tau) d\tau = 1. \quad (75)$$

11.2 Version avec facteur latent exogène

Si une variation lente commune subsiste :

$$\lambda_k(t) = \bar{\mu}_k s_k(\tau(t)) e^{\sigma_k z_g} + \sum_{\ell=1}^K \sum_{t_j^\ell < t} \alpha_{k\ell} \beta_{k\ell} e^{-\beta_{k\ell}(t-t_j^\ell)}, \quad (76)$$

pendant que t appartient à la cellule temporelle g , avec

$$z_g = \rho z_{g-1} + \eta_g, \quad \eta_g \sim \mathcal{N}(0, q). \quad (77)$$

Cette version sur grille est plus simple à estimer qu'un facteur mis à jour à chaque événement et sépare les échelles temporelles.

11.3 Version SCI multiplicative fidèle au papier

Pour rester proche de Bauwens et Hautsch :

$$\lambda_k(t) = \Phi_i^k \lambda_{0,k}(t) s_k(\tau(t)) \exp(\sigma_k^* l_i^*), \quad t_{i-1} < t \leq t_i, \quad (78)$$

avec

$$\tilde{\Phi}_i = \sum_{k=1}^K \left(A^k \varepsilon_{i-1} + B^k \tilde{\Phi}_{i-1} \right) y_{i-1}^k, \quad (79)$$

$$l_i^* = a^* l_{i-1}^* + u_i^*. \quad (80)$$

Cette spécification est riche, mais la simultanéité d'une dynamique ACI persistante et d'un facteur latent persistant peut produire une identification faible. Elle exige un échantillon important, des restrictions parcimonieuses et des diagnostics approfondis.

12 Plan d'implémentation algorithmique

12.1 Pré-estimation de la saisonnalité

1. Construire une table $(d, b, k, C_{kdb}, E_{db})$.
2. Estimer un modèle de Poisson avec offset $\log E_{db}$ et spline cyclique de τ_b .
3. Prédire le taux relatif sur une grille fine.
4. Diviser la courbe par sa moyenne pondérée par l'exposition.
5. Conserver le profil et l'interpoler aux dates exactes des événements.

12.2 Recursion Hawkes exponentielle

Pour un noyau exponentiel, définir juste avant t_i

$$R_{k\ell}(t_i^-) = \sum_{t_j^\ell < t_i} e^{-\beta_{k\ell}(t_i - t_j^\ell)}. \quad (81)$$

Si $\Delta_i = t_i - t_{i-1}$,

$$R_{k\ell}(t_i^-) = e^{-\beta_{k\ell}\Delta_i} \left[R_{k\ell}(t_{i-1}^-) + \mathbf{1}\{m_{i-1} = \ell\} \right]. \quad (82)$$

L'intensité à l'événement i est

$$\lambda_k(t_i^-) = \bar{\mu}_k s_k(\tau(t_i)) + \sum_{\ell=1}^K \alpha_{k\ell} \beta_{k\ell} R_{k\ell}(t_i^-). \quad (83)$$

Cette recursion évite de sommer sur toute l'histoire à chaque événement.

L'intégrale du noyau exponentiel sur $[0, T]$ est

$$\sum_{t_j^\ell < T} \alpha_{k\ell} \left[1 - e^{-\beta_{k\ell}(T - t_j^\ell)} \right]. \quad (84)$$

L'intégrale de la baseline saisonnière peut être pré-calculée par jour et par type.

12.3 Paramétrisation numérique

Pour imposer les contraintes, utiliser

$$\bar{\mu}_k = e^{\xi_k}, \quad (85)$$

$$\alpha_{k\ell} = \text{softplus}(a_{k\ell}), \quad (86)$$

$$\beta_{k\ell} = e^{b_{k\ell}}. \quad (87)$$

La contrainte de rayon spectral peut être obtenue par une reparamétrisation de la matrice ou par une pénalité barrière. En grande dimension, une pénalité ℓ_1 ou group-lasso sur les amplitudes peut sélectionner les interactions.

12.4 Validation hors échantillon

Comparer les modèles par :

- log-vraisemblance prédictive ;
- score de probabilité des comptes sur des horizons opérationnels ;
- calibration des intervalles prédictifs ;
- stabilité des paramètres ;
- précision de la prévision de la prochaine durée ;
- capacité à prévoir les proportions de types d'événements.

Une amélioration in-sample du SCI ne suffit pas à justifier le coût d'un facteur latent. Il faut qu'elle se traduise par une meilleure calibration ou une meilleure prévision hors échantillon.

13 Points de vigilance statistiques

13.1 Nombre de cycles et complexité de la saisonnalité

Une saisonnalité à B tranches nécessite suffisamment de répétitions dans chaque tranche. Si le nombre de jours est faible, une grille très fine donne des estimations bruitées. Les degrés de liberté effectifs du lissage doivent être choisis en fonction du nombre de cycles, pas seulement du nombre total d'événements.

13.2 Hétérogénéité entre jours

Si le niveau moyen varie beaucoup entre jours, une moyenne simple des comptes par tranche mélange profil intrajournalier et effets de jour. On peut utiliser

$$\log \mu_{kd}(t) = \alpha_{kd} + f_k(\tau(t)), \quad (88)$$

où α_{kd} est un effet de niveau quotidien. Le profil f_k est alors estimé à partir de la forme relative au sein des jours.

13.3 Ruptures structurelles

Une courbe saisonnière fixe est inadaptée si le profil change après une modification institutionnelle, une nouvelle politique, une mise à jour de système ou une crise. On peut :

- estimer des profils par régime ;
- utiliser des fenêtres glissantes ;
- autoriser une évolution lente des coefficients saisonniers ;
- inclure des interactions entre l’heure et le régime.

13.4 Bords de fenêtre

L’excitation générée avant le début de la fenêtre est non observée. Les options sont :

- conserver une période de chauffe et exclure sa contribution à la vraisemblance ;
- initialiser les recursions à leur moyenne stationnaire ;
- estimer ou intégrer un état initial ;
- choisir des fenêtres suffisamment longues par rapport à la mémoire du noyau.

13.5 Covariables et prévisibilité

Une covariable utilisée dans l’intensité doit être connue juste avant t . Une variable calculée à partir d’informations futures crée une fuite d’information et invalide la vraisemblance conditionnelle. Pour chaque covariable, il faut documenter son horodatage et la convention gauche/droite de mise à jour.

14 Conclusion

Le modèle SCI de Bauwens et Hautsch propose une décomposition ambitieuse : une composante observable ACI, une saisonnalité déterministe, une intensité de base et un facteur latent commun. Le facteur latent est lognormal avec une dynamique AR(1) en temps événementiel et son estimation exige d’intégrer une trajectoire d’états non observés, ce qui conduit au maximum de vraisemblance simulé et à l’EIS.

La dynamique ACI répond aux erreurs de prévision de l’intensité intégrée. Elle est adaptée lorsque l’on veut modéliser un niveau conditionnel mis à jour par la surprise associée à la dernière durée. Un Hawkes répond à une question différente : comment chaque événement déclenche-t-il une augmentation temporaire des arrivées futures ? Il est donc possible de remplacer l’ACI par un Hawkes, mais il faut choisir consciemment entre une structure SCI multiplicative et une structure additive séparant l’activité de fond de l’excitation.

Pour la saisonnalité, les méthodes les plus opérationnelles sont souvent plus simples que la spécification complète du papier : taux par tranches corrigés de l’exposition, GAM de Poisson, spline cyclique, forme de Fourier ou transformation en temps d’activité. La normalisation à moyenne unitaire est indispensable. La courbe peut être estimée sur un échantillon d’apprentissage puis fixée pendant l’estimation du Hawkes, ce qui améliore la stabilité et clarifie l’identification.

Séquence recommandée :

saisonnalité déterministe → Hawkes ou ACI observable
→ diagnostics → facteur latent si nécessaire.

Cette progression réduit le risque d’attribuer au facteur latent ou à l’auto-excitation ce qui relève simplement d’un profil saisonnier répétitif.

A Annexe A : formules récapitulatives

A.1 SCI original

$$\lambda_k(t) = \lambda_{o,k}(t)(\lambda_i^*)^{\sigma_k^*}, \quad (89)$$

$$\lambda_{o,k}(t) = \Phi_i^k \lambda_{0,k}(t) s_k(\tau(t)), \quad (90)$$

$$\log \lambda_i^* = a^* \log \lambda_{i-1}^* + u_i^*, \quad u_i^* \sim \mathcal{N}(0, 1). \quad (91)$$

A.2 ACI univarié simple

$$\varepsilon_i = 1 - \int_{t_{i-1}}^{t_i} \lambda_o(u) du, \quad (92)$$

$$\tilde{\Phi}_i = \omega + \alpha \varepsilon_{i-1} + \beta(\tilde{\Phi}_{i-1} - \omega), \quad (93)$$

$$\Phi_i = e^{\tilde{\Phi}_i}. \quad (94)$$

A.3 Hawkes saisonnier

$$\lambda_k(t) = \bar{\mu}_k s_k(\tau(t)) + \sum_{\ell=1}^K \int_{(-\infty, t)} \phi_{k\ell}(t-u) dN_\ell(u), \quad (95)$$

$$\phi_{k\ell}(v) = \alpha_{k\ell} \beta_{k\ell} e^{-\beta_{k\ell} v} \mathbf{1}\{v > 0\}. \quad (96)$$

A.4 Hawkes avec facteur latent sur la baseline

$$\lambda_k(t) = \bar{\mu}_k s_k(\tau(t)) e^{\sigma_k z(t)} + \sum_{\ell=1}^K \int_{(-\infty, t)} \phi_{k\ell}(t-u) dN_\ell(u), \quad (97)$$

$$z_g = \rho z_{g-1} + \eta_g. \quad (98)$$

A.5 Saisonnalité positive et normalisée

$$s_k(\tau) = \exp\{B(\tau)' \gamma_k - c_k\}, \quad (99)$$

$$c_k = \log \left[\frac{1}{P} \int_0^P \exp\{B(v)' \gamma_k\} dv \right]. \quad (100)$$

B Annexe B : liste de contrôle empirique

1. Les périodes d'exposition sont-elles correctement définies ?
2. Le nombre de cycles est-il suffisant pour le degré de flexibilité saisonnière ?
3. La saisonnalité est-elle normalisée à moyenne unitaire ?

4. La baseline est-elle suffisamment lisse par rapport à la mémoire Hawkes ?
5. Les résultats sont-ils stables sous plusieurs granularités saisonnières ?
6. Le rayon spectral du Hawkes est-il inférieur à un avec une marge raisonnable ?
7. Les temps transformés sont-ils exponentiels et indépendants ?
8. Les résidus présentent-ils encore une structure lente ou commune ?
9. Le facteur latent améliore-t-il la prévision hors échantillon ?
10. Les covariables sont-elles réellement prévisibles à la date où elles entrent dans l'intensité ?

Références

Références

- [1] L. Bauwens et N. Hautsch, « Stochastic Conditional Intensity Processes », *Journal of Financial Econometrics*, vol. 4, no 3, p. 450–493, 2006. DOI : 10.1093/jjfinec/nbj013.
- [2] L. Bauwens et N. Hautsch, « Modelling Financial High Frequency Data Using Point Processes », dans T. G. Andersen et al. (dir.), *Handbook of Financial Time Series*, Springer, p. 953–979, 2009.
- [3] N. Hautsch, « Generalized Autoregressive Conditional Intensity Models with Long Range Dependence », document de travail, University of Copenhagen, 2006.
- [4] J. R. Russell, « Econometric Modeling of Multivariate Irregularly-Spaced High-Frequency Data », document de travail, University of Chicago, 1999.
- [5] R. F. Engle et J. R. Russell, « Autoregressive Conditional Duration : A New Model for Irregularly Spaced Transaction Data », *Econometrica*, vol. 66, p. 1127–1162, 1998.
- [6] A. G. Hawkes, « Spectra of Some Self-Exciting and Mutually Exciting Point Processes », *Biometrika*, vol. 58, p. 83–90, 1971.
- [7] A. G. Hawkes et D. Oakes, « A Cluster Process Representation of a Self-Exciting Process », *Journal of Applied Probability*, vol. 11, p. 493–503, 1974.
- [8] T. C. Brown et M. G. Nair, « A Simple Proof of the Multivariate Random Time Change Theorem for Point Processes », *Journal of Applied Probability*, vol. 25, p. 210–214, 1988.
- [9] Y. Ogata, « Statistical Models for Earthquake Occurrences and Residual Analysis for Point Processes », *Journal of the American Statistical Association*, vol. 83, p. 9–27, 1988.
- [10] T. Omi, Y. Hirata et K. Aihara, « Hawkes Process Model with a Time-Dependent Background Rate and Its Application to High-Frequency Financial Data », *Physical Review E*, vol. 96, 012303, 2017. DOI : 10.1103/PhysRevE.96.012303.
- [11] J.-F. Richard, « Efficient High-Dimensional Monte Carlo Importance Sampling », document de travail, University of Pittsburgh, 1998.