

Pipeline statistique complet

Transmission de l'information equity index vers la courbe des futures sur dividendes

Données : 7 datasets intraday 9h-17h30, 2024-debut 2026 | ts, mid_t, V_t, Imbalance_t | FESX + D0y...D5y

0. Avis sur la méthodologie d'extraction actuelle

La méthodologie est saine comme base de travail : extraction parallèle, filtrage 9h-17h30, agrégation à 1 seconde, puis construction d'un panel homogène. Le point critique est de ne pas confondre la fréquence de stockage avec la fréquence finale d'analyse.

1 seconde = fréquence canonique de stockage / normalisation, pas nécessairement fréquence finale de modélisation

Choix méthodologique	Avis statistique	Condition / correction
Parallélisation extraction	Bonne idée	Auditer intégrité : timestamps, timezone, doublons, jours incomplets, roll.
Filtre 9h-17h30	Bon échantillon principal	Tester une robustesse 8h-17h30 ou full regular session si disponible.
Agrégation 1s	Bonne base canonique	Ne pas estimer forcément les modèles finaux à 1s. Construire 1min, 10min, daily.
NA volume -> 0	Correct si absence d'activité	Ne pas remplacer par 0 si un événement existe mais volume manquant.
NA imbalance -> 0	Correct seulement si V=0	Si V>0 et imbalance NA : conserver NA, recalculer ou flagger.
mid NA conservé	Bonne pratique pour base brute	Créer aussi mid_ffill avec stale_age et stale_flag pour l'analyse.

Recommandation centrale : garder deux versions des prix, raw et analytique. La version raw conserve les NA pour l'audit ; la version analytique utilise un forward-fill contrôlé par un indicateur d'ancienneté du prix.

$Stale_t^m = 1\{age_t^m > seuil\}$, où $age_t^m = t - \text{dernier timestamp avec mid observé}$

1. Objectif de recherche

L'objectif est de tester si l'information contenue dans le future EURO STOXX 50 se transmet à la courbe des futures sur dividendes de maturité 0y à 5y, puis de vérifier si cette transmission peut être exploitée en market making.

Question 1 : $r_t^F, V_t^F, Imbalance_t^F \rightarrow \Delta D_{t+h}^m$?

Question 2 : $|E[\Delta D_{t+h}^m | information_t]| > \text{coûts de trading}$?

2. Structure de données recommandée

Construire deux représentations complémentaires : un panel large pour les corrélations, PCA et VAR ; un panel long pour les régressions panel avec effets fixes et interactions de maturité.

Format	Structure	Utilisation principale
Large	ts, mid_F, V_F, lmb_F, mid_D0...mid_D5, V_D0...V_D5, lmb_D0...lmb_D5	Corrélations, courbe, PCA, VAR, diagnostics globaux.
Long	ts, maturity, mid_D, V_D, lmb_D, r_F, V_F, lmb_F, variables de temps	Régressions panel, effets fixes maturité, interactions, validation.

$$D_t = (D_t^0, D_t^1, D_t^2, D_t^3, D_t^4, D_t^5)$$

3. Audit et propreté des données

3.1 Audit des timestamps

- timestamps triés et uniques ou agrégés correctement
- timezone cohérente, gestion heure été/hiver
- couverture quotidienne entre 9h et 17h30
- jours incomplets flaggés
- maturité dividend correctement rollée

3.2 Audit des variables

- mid_t > 0 ou NA justifié
- V_t >= 0
- Imbalance_t dans [-1,1] si normalisée
- taux de missing par variable et par maturité
- fraction de buckets sans volume

3.3 Stale prices

- calculer age_t depuis dernière mise à jour mid
- stale_ratio par maturité
- active_ratio = P(V_t > 0)
- ne pas interpréter Delta D=0 comme absence de signal si le mid est stale

Métrique qualité	Formule / définition	Interprétation
ActiveRatio_m	$\#\{t: V_t^m > 0\} / \#t$	Activité observable de la maturité m.
StaleRatio_m	$\#\{t: \text{mid}_t^m \text{ inchangé ou stale}\} / \#t$	Risque d'underestimate de la transmission.
MissingMid_m	$\#\{t: \text{mid}_t^m \text{ NA}\} / \#t$	Couverture du prix.
InvalidImb_m	$\#\{ \text{Imb}_t^m > 1\} / \#t$	Erreur de construction ou imbalance non normalisée.

4. Traitement des valeurs extrêmes et aberrantes

Il faut distinguer une valeur extrême réelle, qui doit être conservée mais flaggée, d'une valeur aberrante de donnée, qui doit être corrigée ou exclue.

Cas	Exemple	Traitement
Extrême réel	BCE, CPI, stress marché, grosse révision dividend	Garder, flagger ExtremeDay/ExtremeBucket.
Aberrant technique	mid=0, spike isolé qui revient immédiatement, mauvaise maturité	Corriger si possible, sinon exclure.
Volume extrême	gros block ou activité anormale	Garder, utiliser log(1+V), flagger quantile 99.5%.
Imbalance ±1	tout le volume dans un sens	Normal si V significatif ; peu informatif si V très faible.

$$z_t^{\text{robust}} = 0.6745 * (x_t - \text{median}(x)) / \text{MAD}(x)$$

Une bonne pratique est de produire trois versions : dataset nettoyé avec extrêmes, dataset winsorisé pour robustesse, dataset hors jours extrêmes.

5. Agrégations à produire

Fréquence	Rôle	Variables clés	Recommandation
1 seconde	Base canonique après extraction	mid_raw, mid_ffill, V, Imb,	Oui, mais pas forcément pour

		stale_age	modèle final.
1 minute	Descriptif haute fréquence	r_F, DeltaD, V, lmb	Seulement maturités liquides.
10 minutes	Modèle intraday principal	lags de r_F, lmb_F, log(1+V_F)	Fréquence centrale.
Daily	Transmission économique	open-close ou close-close	Indispensable.
Event-time	Maturités peu liquides	moments de repricing ou volume positif	Très utile en complément.

$$lmb_bucket = sum(lmb_i * V_i) / sum(V_i), \text{ si } sum(V_i)>0 ; \text{ sinon } lmb_bucket = 0$$

6. Analyse descriptive

Analyse	Pourquoi	Sorties attendues
Par maturité	Comparer liquidité et qualité des prix	volume, active ratio, stale ratio, vol, imbalance.
Par heure	Contrôler saisonnalité intraday	profils horaires de volume, stale, vol, imbalance.
Par année	Tester stabilité 2024/2025/2026	tableaux par sous-période.
Courbe dividend	Voir niveau/pente/courbure	Level, Slope, Curvature, PCA.
Extrêmes	Ne pas laisser quelques jours dominer	outlier tables, flags, robustness.

$$Level_t = (1/6) * sum_{m=0}^5 D_t^m$$

$$Slope_t = D_t^5 - D_t^0$$

$$Curvature_t = D_t^0 - 2D_t^2 + D_t^5$$

7. Corrélations et lead-lag

Oui, les corrélations sont nécessaires, mais elles doivent être calculées en contemporain et avec lags. Les corrélations ne prouvent pas l'exploitabilité, mais elles guident les modèles.

$$Corr_lag(m,l) = Corr(r_{-l}^F, Delta D_t^m)$$

$$Corr lmb_lag(m,l) = Corr(Imbalance_{-l}^F, Delta D_t^m)$$

Corrélation	Question
Corr(r_F, DeltaD_m)	La maturité m réagit-elle au mouvement index ?
Corr(lmb_F, DeltaD_m)	L'orderflow index contient-il de l'information ?
Corr(logV_F, DeltaD_m)	L'activité index coïncide-t-elle avec un repricing dividend ?
Corr(DeltaD_i, DeltaD_j)	La courbe bouge-t-elle en bloc ?
Corr_lag heatmap	Y a-t-il lead-lag exploitable ?

8. Sélection statistique des variables

La sélection doit combiner raisonnement économique et validation temporelle. Ne pas utiliser de cross-validation aléatoire sur des données intraday.

Famille de variables	Variables candidates
Index	r_F laggé, lmb_F laggé, log(1+V_F) laggé, RV_F.
Dividend local	DeltaD_m laggé, lmb_D_m, log(1+V_D_m), active/stale flags.
Temps	hour/TOD, day fixed effects, year, roll flag, extreme flag.
Courbe	Level, Slope, Curvature, PCA factors.

9. Modèles recommandés

9.1 Benchmark

$\hat{y}_t^m = 0$ ou moyenne historique de ΔD^m

9.2 Régression par maturité

$\Delta D_t^m = \alpha_m + \sum_l \beta_{\{m,l\}} r_{\{t-l\}}^F + \sum_l \gamma_{\{m,l\}} lmb_{\{t-l\}}^F + \sum_l \eta_{\{m,l\}} \log(1+V_{\{t-l\}}^F) + \epsilon_{t,m}$

9.3 Panel avec effets fixes

$\Delta D_t^m = \alpha_m + \Delta_{TOD} + \Delta_{day} + \text{interactions maturité} \times \text{lags} + \text{variables locales} + \epsilon_{\{t,m\}}$

9.4 Modèle de courbe

$\Delta Level_t, \Delta Slope_t, \Delta Curvature_t$ expliqués par $r_F, lmb_F, \log(1+V_F)$

9.5 VAR / IRF par maturité

$Y_t^m = (r_t^F, \Delta D_t^m)$, puis $IRF_{\{D^m <- F\}}(h)$

10. Validation hors-échantillon

Test	Définition	Pourquoi
Split temporel	Train 2024, validation 2025, test debut 2026 ou walk-forward	Evite leakage temporel.
R2 OOS	1 - SSE_model/SSE_benchmark	Mesure performance prédictive.
Hit ratio	$P(\text{sign}(\hat{y})=\text{sign}(y))$	Utile pour direction.
Robust SE	Newey-West ou cluster par jour	Corrige autocorrélation intraday.
Stabilité	par année, maturité, heure, régime	Evite faux signal local.

$R2_OOS = 1 - \sum (y_t - \hat{y}_t)^2 / \sum (y_t - \bar{y}_{train})^2$

11. Exploitabilité market making

Le signal n'est exploitable que s'il dépasse les coûts et s'il existe assez de liquidité sur la maturité concernée.

$Edge_t^m = |\hat{y}_t^m| - Cost_t^m$

$Cost_t^m = half_spread_t^m + fees + slippage + adverse_selection + stale_risk$

$Position_t^m = +1 \text{ si } \hat{y}_t^m > Cost_t^m ; -1 \text{ si } \hat{y}_t^m < -Cost_t^m ; 0 \text{ sinon}$

Critère	Question
OOS positif	Le signal prédit-il hors-échantillon ?
Après coûts	Le signal bat-il spread/frais/slippage ?
Capacité	Y a-t-il du volume pour agir ?
Stabilité	Le signal survit-il aux sous-périodes ?

12. Ordre exact des analyses

- 1. Audit brut des 7 datasets.
- 2. Contrôle timestamps, missing, contraintes et roll.
- 3. Construction base 1s raw avec mid NA conservé.

4. Construction base 1s analytique avec mid_ffill et stale flags.
5. Agrégations 1min, 10min, daily et event-time.
6. Statistiques par maturité et par heure.
7. Détection valeurs aberrantes et flags extrêmes.
8. Corrélations contemporaines et laggées.
9. Heatmaps maturité x lag pour r_F et Imb_F.
10. Analyse de courbe Level/Slope/Curvature/PCA.
11. Régressions par maturité.
12. Régression panel avec effets fixes et interactions.
13. Sélection par raisonnement économique + Elastic Net walk-forward.
14. Validation hors-échantillon.
15. Backtest proxy après coûts.
16. Conclusion : transmission économique seulement ou signal exploitable.

13. Conclusion opérationnelle

La méthodologie recommandée est : extraire et standardiser à 1 seconde, conserver les mids bruts avec NA, construire une version analytique contrôlée par stale flags, puis estimer principalement en 10 minutes et en daily. La question centrale se lit dans les matrices $\beta_{m,l}$ et $\gamma_{m,l}$.

$\beta_{m,l}$ = sensibilité de la maturité m au rendement index laggé l

$\gamma_{m,l}$ = sensibilité de la maturité m à l'imbalance index laggée l

Une transmission statistique est intéressante ; une transmission exploitable doit être stable hors-échantillon et positive après coûts.

Références utiles

- Hasbrouck, J. (1991) - Measuring the Information Content of Stock Trades, Journal of Finance.
- Cont, R., Kukanov, A., Stoikov, S. (2014) - The Price Impact of Order Book Events, Journal of Financial Econometrics.
- Bacry, E., Mastromatteo, I., Muzy, J.-F. (2015) - Hawkes Processes in Finance, Market Microstructure and Liquidity.
- Filipovic, D., Willems, S. (2020) - A Term Structure Model for Dividends and Interest Rates, Mathematical Finance.